BỘ GIÁO DỤC VÀ ĐÀO TẠO

ĐẠI HỌC PHENIKAA

———————————o0o———————————

BÁO CÁO THUẬT TOÁN ỨNG DỤNG

TÌM ĐƯỜNG TỐI ƯU TRONG MẠNG GIAO THÔNG ĐỘNG QUẬN HÀ ĐÔNG VỚI 24 KHUNG GIỜ

Họ và tên	MSSV	Email
Nguyễn Văn Thăng	23010572	23010572@st.phenikaa-uni.edu.vn
Nguyễn Thị Nhung	23010607	23010607@st.phenikaa-uni.edu.vn
Nguyễn Thị Khánh Linh	23016112	23016112@st.phenikaa-uni.edu.vn

GVHD: TS. Trần Đình Tân

HÀ NỘI - 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO

ĐẠI HỌC PHENIKAA

—————————o0o—————————

BÁO CÁO THUẬT TOÁN ỨNG DỤNG

TÌM ĐƯỜNG TỐI ƯU TRONG MẠNG GIAO THÔNG ĐỘNG QUẬN HÀ ĐÔNG VỚI 24 KHUNG GIỜ

Họ và tên	MSSV	Nhiệm Vụ	Đóng góp
Nguyễn Văn Thăng	23010572	Tìm hiểu tài liệu; Xây dựng đồ thị và mô hình vận tốc; Cài đặt thuật toán; Huấn luyện RL; Đánh giá; Viết báo cáo	33%
Nguyễn Thị Nhung	23010607	Tìm hiểu tài liệu; Xây dựng đồ thị và mô hình vận tốc; Cài đặt thuật toán; Huấn luyện RL; Đánh giá; Viết báo cáo	33%
Nguyễn Thị Khánh Linh	23016112	Tìm hiểu tài liệu; Xây dựng đồ thị và mô hình vận tốc; Cài đặt thuật toán; Huấn luyện RL; Đánh giá; Viết báo cáo	33%

GVHD: TS. Trần Đình Tân

HÀ NỘI - 2026

Mục lục

1 Giới thiệu **6**
1.1 Bối cảnh và động lực nghiên cứu 6
1.2 Mục tiêu của đề tài 7
1.3 Đóng góp chính của đề tài 9
1.4 Cấu trúc báo cáo 9

2 Phát biểu bài toán **10**
2.1 Mô tả bài toán 10
2.2 Mô hình hoá toán học 11
2.3 Khó khăn và thách thức 13

3 Nghiên cứu liên quan **14**
3.1 Các phương pháp truyền thống 14
3.2 Các hướng tiếp cận hiện đại 15
3.3 Phân tích điểm mạnh / hạn chế 16

4 Phương pháp đề xuất **17**
4.1 Ý tưởng tổng quát 17
4.2 Chi tiết thuật toán / mô hình 18
4.2.1 Xây dựng đồ thị từ OpenStreetMap 18
4.2.2 Mô hình vận tốc 24 khung giờ 20
4.2.3 Môi trường thực với nhiễu tương quan 23
4.2.4 Tìm kiếm phụ thuộc thời gian và heuristic 24
4.2.5 Tái lập kế hoạch 25
4.2.6 Dự báo ngắn hạn bằng mạng tích chập đồ thị 26
4.2.7 Định tuyến theo rủi ro (P90) 27
4.2.8 Học tăng cường 27
4.2.9 Chọn giờ xuất phát 30
4.2.10 Mô phỏng nhiều xe 30
4.2.11 Ứng dụng minh hoạ và đóng gói 31
4.3 Phân tích độ phức tạp / tính đúng đắn 31
4.4 Lược đồ hoặc sơ đồ minh hoạ 34

5 Kết quả thực nghiệm **36**

5.1 Cấu hình thực nghiệm 36
5.2 Phương pháp baseline để so sánh 37
5.3 Các bộ dữ liệu sử dụng 38
5.4 Các tiêu chí đánh giá 39
5.5 Phân tích kết quả 40
5.5.1 Kết quả tổng hợp: tìm kiếm, tái lập kế hoạch, dự báo . . . 40
5.5.2 Chi phí tính toán 42
5.5.3 Vai trò của sự cố và tập stress 43
5.5.4 Mức nhiễu, dự báo GCN và định tuyến P90 44
5.5.5 Theo giờ xuất phát và khoảng cách 46
5.5.6 Học tăng cường 48
5.5.7 Chọn giờ xuất phát 51
5.5.8 Nhiều xe cùng được dẫn đường 52
5.5.9 Khi nào phương pháp đề xuất tốt hơn, và tại sao 53

6 Kết luận **54**
6.1 Tóm tắt kết quả chính 54
6.2 Đóng góp của đề tài 55
6.3 Hạn chế và hướng phát triển 55

Tài liệu tham khảo **57**

A Phụ lục: Tham số cấu hình **61**

B Phụ lục: Các điểm nóng ùn tắc **61**

Danh mục hình ảnh

4.1 Mạng đường lái xe quận Hà Đông (cộng vùng đệm 500 m) theo nhóm đường; nét đứt là ranh giới quận cũ. 20
4.2 Vận tốc nền trung bình theo giờ và nhóm đường (trái); profile ùn tắc chung $p(h)$ (phải). 22
4.3 Tỉ lệ v/v_{free} trên toàn mạng lúc 3h, 8h, 14h và 18h. 23
4.4 Giao diện ứng dụng minh hoạ (chụp tự động; nền bản đồ không tải trong trình duyệt chạy ẩn). 31
4.5 Sơ đồ khối của hệ thống: luồng dữ liệu từ OpenStreetMap tới đánh giá và báo cáo. 35
5.1 Phân bố regret theo phương pháp trên tập kiểm tra chính (chuyến tới đích; trục tung dạng symlog). 41
5.2 Số nút mở rộng (trái) và thời gian tính đơn luồng (phải) trung bình mỗi truy vấn, thang logarit. 43
5.3 Trái: regret theo mức nhiễu σ khi không có sự cố. Phải: RMSE trên cạnh chưa quan sát trong quá trình huấn luyện GCN. 45
5.4 Trái: regret theo giờ xuất phát. Phải: tiết kiệm của tuyến nhanh nhất so với tuyến ngắn nhất theo giờ. 46
5.5 Regret theo số sự cố, mức nhiễu và khoảng cách (thanh lỗi: khoảng tin cậy bootstrap 95%; trục symlog). 48
5.6 Đường cong học trên tập kiểm định: trung bình và dải min–max qua 3 seed (trục hoành symlog). 48
5.7 Ví dụ truy vấn test_0169 (truy vấn có sự cố với chênh lệch giữa plan-once và replan lớn nhất). 51
5.8 Chọn giờ xuất phát: chi phí trung bình theo chính sách (trái) và tỉ lệ chọn chờ theo giờ (phải). 52
5.9 Thời gian đi trung bình theo số xe được dẫn đường cùng lúc. . . 53

Danh mục bảng biểu

3.1 So sánh định tính các họ phương pháp tìm đường. 17
4.1 Phân bố loại đường của đồ thị Hà Đông (sau làm sạch). 19
4.2 Các biến thể học tăng cường (mỗi biến thể huấn luyện với 3 seed). 30
4.3 Độ phức tạp thời gian và bộ nhớ của các thành phần. 34

5.1 Môi trường phần cứng và phần mềm. 37
5.2 Kết quả các phương pháp tìm kiếm và dự báo trên tập kiểm tra chính (200 truy vấn, sự cố đặt ngẫu nhiên) trong môi trường thực; regret tính so với oracle. 40
5.3 So sánh ghép cặp trên các truy vấn cả hai phương pháp cùng tới đích: khoảng tin cậy bootstrap 95% của hiệu trung bình thời gian và kiểm định Wilcoxon signed-rank. 42
5.4 Chi phí tính toán đơn luồng (một tiến trình, tuần tự, 50 truy vấn kiểm tra, sau khi làm nóng). Với RL, cột nút mở rộng là số bước chính sách. 43
5.5 Regret trung bình (%) so với oracle theo số sự cố (chuyến tới đích). 44
5.6 Kết quả trên tập stress (sự cố được ưu tiên đặt trên tuyến dự kiến với xác suất 0.7): cùng 200 truy vấn, cùng thời điểm/mức độ sự cố. 44
5.7 Kết quả trên tập con kiểm tra không có sự cố (81 truy vấn). . . . 44
5.8 Sai số dự báo log-tỉ số vận tốc (mốc h và $h+1$) trên 20 trường kiểm định độc lập; 1341 cảm biến (15% cạnh) + cạnh trong bán kính quan sát. 45
5.9 Regret trung bình (%) theo mức nhiễu σ khi không có sự cố. . . 45
5.10 Độ tin cậy tuyến trên 100 kịch bản nhiễu độc lập cho mỗi truy vấn (100 truy vấn kiểm tra, không sự cố). Tuyến P90 khác tuyến plan-once ở 20% truy vấn. 46
5.11 Regret trung bình (%) so với oracle theo giờ xuất phát (cao điểm: 7h, 8h, 17h, 18h) (chuyến tới đích). 47
5.12 Regret trung bình (%) so với oracle theo khoảng cách O–D (chuyến tới đích). 47
5.13 Regret trung bình (%) so với oracle theo mức nhiễu σ (chuyến tới đích). 47
5.14 Tiết kiệm thời gian của tuyến nhanh nhất so với tuyến ngắn nhất (trên vận tốc nền) theo giờ xuất phát. 47
5.15 Kết quả các biến thể học tăng cường (seed tốt nhất theo tập kiểm định) và baseline tham lam trên cùng tập kiểm tra; thời gian và regret chỉ tính trên các chuyến tới đích. 48

5.16 Kết quả học tăng cường theo từng seed (checkpoint tốt nhất theo tập kiểm định; cột Chọn đánh dấu seed dùng cho bảng chính). . 50
5.17 Độ trùng tuyến giữa các cặp phương pháp trên tập kiểm tra chính. 50
5.18 Kết quả thí nghiệm chọn giờ xuất phát trên tập kiểm tra (bước chờ 10 phút, tối đa 6 lần). 52
5.19 Thời gian đi trung bình (phút) khi nhiều xe được dẫn đường cùng lúc; V/C là tỉ số lớn nhất giữa lưu lượng dẫn đường và năng lực. 53
A.1 Tham số cấu hình chính (configs/config.yaml). 62
B.1 Các điểm nóng (giả định cần hiệu chỉnh) và số cạnh được khớp. 63

1 Giới thiệu

1.1 Bối cảnh và động lực nghiên cứu

Lĩnh vực ứng dụng. Bài toán tìm đường (route planning) là một trong những bài toán kinh điển nhất của khoa học máy tính và đồng thời là thành phần lõi của các hệ thống giao thông thông minh (Intelligent Transportation Systems): ứng dụng bản đồ và dẫn đường trên điện thoại, nền tảng gọi xe công nghệ, điều phối xe giao hàng chặng cuối, quản lý đội xe buýt hay xe cứu thương. Ở dạng đơn giản nhất, mạng đường được mô hình hoá thành một đồ thị có hướng có trọng số và câu hỏi đặt ra là tìm đường đi có tổng trọng số nhỏ nhất giữa hai đỉnh; thuật toán Dijkstra [1] và A* [2] giải trọn vẹn câu hỏi đó trong thời gian đa thức.

Trong thực tế đô thị, giả thiết "trọng số cố định" lại hiếm khi đúng. Thời gian để đi qua một đoạn đường phụ thuộc mạnh vào *thời điểm* đi vào đoạn đó: cùng một trục đường có thể thông thoáng lúc ba giờ sáng nhưng ùn tắc kéo dài lúc tám giờ sáng. Hệ quả là tuyến đường ngắn nhất theo chiều dài không nhất thiết là tuyến nhanh nhất, và tuyến nhanh nhất lúc này không nhất thiết là tuyến nhanh nhất một giờ sau. Đây chính là bài toán *đường đi ngắn nhất phụ thuộc thời gian* (time-dependent shortest path, TDSP) [3–5].

Nhu cầu và vấn đề thực tiễn. Hà Đông là quận cửa ngõ phía tây nam của Hà Nội (trước khi sắp xếp lại đơn vị hành chính năm 2025), nơi tập trung nhiều khu đô thị mới và các trục hướng tâm chịu lưu lượng lớn như Quang Trung – Nguyễn Trãi, Tố Hữu (Lê Văn Lương kéo dài), Văn Khê và Quốc lộ 6. Ùn tắc ở khu vực này mang ba đặc điểm điển hình của giao thông đô thị Việt Nam:

- *tính chu kỳ theo ngày*: ùn tắc lặp lại vào các khung giờ cao điểm sáng và chiều;
- *tính có hướng*: buổi sáng dòng xe đổ vào trung tâm thành phố, buổi chiều theo chiều ngược lại;
- *tính bất định*: ngày này khác ngày kia, và có các sự cố bất thường (va chạm, ngập, sửa đường) làm một đoạn đường chậm hẳn trong một khoảng thời gian.

Với người tham gia giao thông, các câu hỏi rất cụ thể: nên đi tuyến nào khi xuất phát lúc 7 giờ 45? Khi thấy phía trước ùn tắc có nên rẽ sang đường khác? Có nên đợi thêm nửa tiếng để tránh cao điểm hay không? Khi rất nhiều người cùng dùng một ứng dụng chỉ đường, chỉ dẫn "nhanh nhất" có còn nhanh nhất?

Song song với đó, các phương pháp học máy — đặc biệt là học tăng cường (Reinforcement Learning, RL) và mạng nơ-ron đồ thị (Graph Neural Network, GNN) — được kỳ vọng nhiều cho định tuyến. RL hứa hẹn học được chính sách ra quyết định trực tiếp từ trải nghiệm mà không cần mô hình tường minh [6]; GNN có khả năng khai thác cấu trúc đồ thị của mạng đường để dự báo vận tốc [7,8]. Tuy nhiên các phương pháp cổ điển như TD-A* lại có bảo đảm tối ưu (dưới các giả thiết hợp lý) và chạy rất nhanh. Câu hỏi then chốt vì vậy không phải "RL có dùng được không" mà là *trong những điều kiện nào thì phương pháp học có lợi hơn thuật toán cổ điển, và lợi bao nhiêu*. Để trả lời công bằng, mọi phương pháp phải được đánh giá trên cùng một mạng đường thật, cùng một tập truy vấn kiểm tra, cùng một môi trường mô phỏng và cùng một bộ chỉ số — đó là động lực chính của đề tài.

1.2 Mục tiêu của đề tài

Mục tiêu chính. Xây dựng một khung thực nghiệm hoàn chỉnh, chạy được trên máy tính cá nhân chỉ có CPU và *tái lập được* (cố định seed, toàn bộ tham số nằm trong một tệp cấu hình), đi từ dữ liệu bản đồ mở OpenStreetMap [9] tới báo cáo; trong đó mô phỏng vận tốc theo 24 khung giờ cho mạng đường Hà Đông, cài đặt và so sánh công bằng các họ phương pháp tìm đường phụ thuộc thời gian, tái lập kế hoạch, dự báo ngắn hạn bằng GNN, định tuyến theo rủi ro và học tăng cường; đồng thời cung cấp giao diện minh hoạ trực quan.

Mục tiêu cụ thể.

(1) Thu thập và chuẩn hoá mạng đường lái xe quận Hà Đông từ OpenStreetMap, xử lý các tình huống thực tế (ranh giới hành chính thay đổi, máy chủ dữ liệu không phản hồi, thiếu thuộc tính tốc độ).

(2) Xây dựng mô hình vận tốc 24 khung giờ có cấu trúc, bảo đảm tính FIFO (đi trước thì đến trước), kèm mô hình nhiễu và sự cố cho "môi trường thực".

(3) Cài đặt hiệu quả các thuật toán: Dijkstra, A*, TD-Dijkstra, TD-A* với nhiều heuristic, phiên bản biên dịch JIT, tái lập kế hoạch (đầy đủ, lười, D* Lite), dự báo bằng mạng tích chập đồ thị và định tuyến theo phân vị.

(4) Thiết kế môi trường học tăng cường chuẩn Gymnasium và huấn luyện nhiều biến thể RL (quan sát cục bộ, quan sát cây lân cận với GNN, bộ nhớ LSTM, học bắt chước, định hình thưởng, kết hợp RL với tìm kiếm).

(5) Đánh giá trên tập kiểm tra cố định với kiểm định thống kê; phân tích theo giờ, mức nhiễu, sự cố, khoảng cách; các thí nghiệm phụ về chọn giờ xuất phát và về hiệu ứng khi nhiều xe cùng được dẫn đường.

Câu hỏi nghiên cứu.

RQ1. Tính đến sự phụ thuộc thời gian (TD-A*) cải thiện thời gian đi bao nhiêu so với tuyến ngắn nhất hoặc tuyến theo vận tốc tự do? Lợi ích thay đổi như thế nào theo giờ trong ngày?

RQ2. Khi dự báo sai (nhiễu ngày, sự cố), tái lập kế hoạch dựa trên quan sát cục bộ, dự báo GNN từ cảm biến, hay định tuyến theo phân vị 90% giúp được bao nhiêu? Có thể tái lập kế hoạch với chi phí tính toán thấp hơn (replan lười, D* Lite) mà không mất chất lượng không?

RQ3. RL chọn từng cạnh có cạnh tranh được với tìm kiếm có mô hình không? Các cải tiến (quan sát rộng hơn, bộ nhớ, học bắt chước, định hình thưởng) và cách kết hợp RL với tìm kiếm giúp đến đâu?

RQ4. Chọn giờ xuất phát có lợi trong điều kiện nào? Điều gì xảy ra khi nhiều xe cùng làm theo một chỉ dẫn?

Giả thuyết. Từ lý thuyết, chúng tôi kỳ vọng: (H1) TD-A* tốt hơn rõ rệt tuyến tĩnh vì nó tối ưu dưới FIFO; (H2) tái lập kế hoạch có lợi chủ yếu khi dự báo sai cục bộ và lớn (sự cố); (H3) RL chọn từng cạnh với thông tin cục bộ khó vượt được tìm kiếm có mô hình, vì nó phải tự học lại cấu trúc đồ thị mà tìm kiếm đã có sẵn; (H4) dẫn đường cá nhân tối ưu có thể làm hệ thống tệ đi khi tỉ lệ người dùng lớn. Phần 5 kiểm chứng từng giả thuyết bằng số liệu.

1.3 Đóng góp chính của đề tài

(1) **Khung thực nghiệm tái lập được.** Toàn bộ quy trình chạy bằng một lệnh, với hai chế độ (*smoke* vài phút để kiểm tra và *full* cho kết quả chính thức); mọi bảng, hình và *mọi con số trong báo cáo này* được sinh tự động từ kết quả chạy, không có số liệu gõ tay.

(2) **Mô hình vận tốc 24 khung giờ cho Hà Đông.** Mô hình có cấu trúc, minh bạch về giả định: profile ùn tắc chu kỳ ngày, độ nhạy theo loại đường, các trục nóng, hiệu ứng hướng vào/ra trung tâm, nhiễu tương quan không gian — thời gian; bảo đảm FIFO kể cả khi có sự cố nhờ thủ tục "FIFO hoá" có chứng minh.

(3) **Bộ thuật toán hiệu quả trên cấu trúc CSR.** TD-A* với ba heuristic (khoảng cách chim bay, cận dưới chính xác, ALT), phiên bản Numba; ba cơ chế tái lập kế hoạch; dự báo GCN từ 15% cạnh có cảm biến; định tuyến theo P90.

(4) **Sáu hướng cải tiến RL trên cùng một môi trường** và một phân tích trung thực về khi nào RL có và không có lợi — bao gồm cả các kết quả âm (RL thua tìm kiếm, định tuyến P90 không có lợi).

(5) **Hai thí nghiệm phụ** (chọn giờ xuất phát bằng Q-learning; mô phỏng nhiều xe với phản hồi tải BPR) và **ứng dụng minh hoạ** trên nền Streamlit, được đóng gói Docker.

1.4 Cấu trúc báo cáo

Phần 2 phát biểu bài toán bằng ngôn ngữ tự nhiên và dưới dạng mô hình toán học, kèm ví dụ minh hoạ và phân tích các khó khăn. Phần 3 tổng quan các nghiên cứu liên quan, gồm các thuật toán cổ điển và các hướng tiếp cận hiện đại, kết thúc bằng bảng so sánh và khoảng trống nghiên cứu. Phần 4 trình bày chi tiết phương pháp đề xuất: dữ liệu, mô hình mô phỏng, từng thuật toán, môi trường học tăng cường, phân tích độ phức tạp và tính đúng đắn, cùng sơ đồ hệ thống. Phần 5 mô tả thiết lập thực nghiệm và phân tích kết quả. Phần 6 tổng kết, nêu hạn chế và hướng phát triển. Phụ lục liệt kê tham số cấu hình và các điểm nóng ùn tắc được giả định.

2 Phát biểu bài toán

2.1 Mô tả bài toán

Cho mạng đường lái xe của quận Hà Đông, một điểm đi, một điểm đến và một giờ xuất phát. Vận tốc trên mỗi đoạn đường thay đổi theo giờ trong ngày theo một quy luật lặp lại; ta có trong tay một *dự báo* của quy luật đó (gọi là vận tốc nền V_{base}). Tuy nhiên ngày thực tế luôn lệch khỏi dự báo: có nhiễu (đường đông hơn hoặc vắng hơn bình thường, và độ lệch này lan sang các đoạn lân cận, kéo dài sang các giờ kế tiếp) và có thể xảy ra *sự cố* làm một đoạn đường chậm hẳn trong 30–120 phút. Người lái chỉ *quan sát* được vận tốc thực trong một bán kính quanh vị trí hiện tại; trong một số thiết lập, có thêm dữ liệu từ các cảm biến cố định trên một phần mạng đường.

Nhiệm vụ là chọn tuyến đường — hoặc chọn một lần lúc xuất phát, hoặc điều chỉnh liên tục trong khi đi — sao cho đến nơi sớm nhất. Bên cạnh đó có ba bài toán phụ: (i) có nên đợi thêm một khoảng thời gian trước khi xuất phát để tránh cao điểm; (ii) chọn tuyến *tin cậy* (ít rủi ro bị trễ) thay vì tuyến nhanh nhất trung bình; (iii) khi nhiều xe cùng được dẫn đường, chỉ dẫn nên được phân bổ thế nào để không tự tạo ra ùn tắc mới.

Đầu vào của một truy vấn gồm: nút đi s, nút đến d, giờ xuất phát t_0; đầu vào của hệ thống gồm đồ thị đường, vận tốc nền 24 khung giờ, và (tuỳ phương pháp) các quan sát thời gian thực. **Đầu ra** là dãy cạnh từ s tới d (hoặc một chính sách chọn cạnh tiếp theo), cùng thời gian di chuyển thực tế phát sinh khi đi theo nó.

Ví dụ 2.1 (Tuyến ngắn nhất không phải lúc nào cũng nhanh nhất). Xét một ví dụ *giả định* để minh hoạ: từ s tới d có hai lựa chọn. Tuyến 1 đi trục chính dài $3{,}0$ km; tuyến 2 đi đường nhánh dài $2{,}4$ km. Lúc 3 giờ sáng, vận tốc trục chính là 50 km/h và đường nhánh 18 km/h, nên

$$T_1(3\text{h}) = \frac{3{,}0}{50} \cdot 60 = 3{,}6 \text{ phút}, \qquad T_2(3\text{h}) = \frac{2{,}4}{18} \cdot 60 \approx 8{,}0 \text{ phút}, \tag{2.1}$$

tuyến 1 (dài hơn) nhanh hơn hẳn. Lúc 8 giờ sáng, trục chính tắc còn 14 km/h, đường nhánh còn 13 km/h:

$$T_1(8\text{h}) = \frac{3{,}0}{14} \cdot 60 \approx 12{,}9 \text{ phút}, \qquad T_2(8\text{h}) = \frac{2{,}4}{13} \cdot 60 \approx 11{,}1 \text{ phút}, \tag{2.2}$$

tuyến 2 trở thành tuyến nhanh nhất. Tuyến tối ưu phụ thuộc vào giờ xuất phát.

Ví dụ 2.2 (Ví dụ thật trong tập kiểm tra). Truy vấn test_0169 trong tập kiểm tra có 2 sự cố trên hành lang đi (Hình 5.7 ở Phần 5). Kế hoạch tốt nhất theo dự báo (plan-once) đi thẳng vào đoạn bị sự cố và mất 22,9 phút; cơ chế tái lập kế hoạch nhận ra đoạn chậm khi đến gần và vòng tránh, chỉ mất 18,7 phút — gần bằng lời giải của một "nhà tiên tri" biết trước toàn bộ tương lai (oracle, 18,2 phút). Ví dụ cho thấy ba yếu tố cốt lõi của bài toán: phụ thuộc thời gian, bất định, và quan sát cục bộ.

2.2 Mô hình hoá toán học

Đồ thị và hàm thời gian. Mạng đường được biểu diễn bởi đồ thị có hướng $G = (V, E)$ với $|V| = n$ nút (giao lộ, điểm cuối đường) và $|E| = m$ cạnh (đoạn đường một chiều). Mỗi cạnh $e = (u, v) \in E$ có chiều dài L_e (mét). Thời gian $t \in \mathbb{R}$ tính bằng phút kể từ 0:00; vận tốc lặp lại với chu kỳ 1440 phút. Ký hiệu $v_e(t) > 0$ (m/phút) là vận tốc trên cạnh e tại thời điểm t.

Định nghĩa 2.1 (Hàm thời gian qua cạnh và hàm đến) Thời gian để đi hết cạnh e khi vào cạnh tại thời điểm t và thời điểm ra khỏi cạnh lần lượt là

$$\tau_e(t) = \frac{L_e}{v_e(t)}, \tag{2.3}$$

$$a_e(t) = t + \tau_e(t). \tag{2.4}$$

Một đường đi từ s tới d là dãy cạnh $P = (e_1, \ldots, e_k)$ với $e_i = (u_{i-1}, u_i)$, $u_0 = s$, $u_k = d$. Thời điểm đến khi xuất phát lúc t_0 được tính bằng cách hợp các hàm đến:

$$A(P, t_0) = a_{e_k} \circ a_{e_{k-1}} \circ \cdots \circ a_{e_1}(t_0). \tag{2.5}$$

Định nghĩa 2.2 (Tính FIFO) Mạng thoả tính *FIFO* (first-in-first-out, đi trước thì đến trước) nếu với mọi cạnh e và mọi $t_1 \le t_2$:

$$a_e(t_1) \le a_e(t_2). \tag{2.6}$$

Khi τ_e khả vi, điều kiện (2.6) tương đương với

$$\frac{d\tau_e(t)}{dt} \ge -1 \qquad \forall t. \tag{2.7}$$

Bài toán TDSP (lập kế hoạch một lần). Với tập $\mathcal{P}(s,d)$ các đường đi từ s tới d:

$$P^* = \arg\min_{P\in\mathcal{P}(s,d)} \big[A(P,t_0) - t_0\big], \tag{2.8}$$

trong đó $v_e(t)$ lấy từ dự báo V_{base} (phương pháp *plan-once*) hoặc từ môi trường thực V_{real} (lời giải *oracle*, chỉ dùng làm cận dưới để đánh giá). Ràng buộc duy nhất là P phải là đường đi hợp lệ trên G (các cạnh nối tiếp nhau); không cho phép chờ tại nút.

Bài toán trực tuyến (tái lập kế hoạch, học tăng cường). Trạng thái đầy đủ tại bước k gồm vị trí u_k, thời điểm t_k và toàn bộ trường vận tốc thực V_{real}; nhưng tác tử chỉ quan sát được

$$o_k = \Big(u_k,\ t_k,\ \big\{\tau_e^{\text{real}}(t_k) : e \in \mathcal{N}_r(u_k)\big\}\Big), \tag{2.9}$$

với $\mathcal{N}_r(u)$ là tập cạnh có nút đầu cách u không quá r mét. Bài toán là một quá trình quyết định Markov quan sát một phần (POMDP): tìm chính sách π ánh xạ lịch sử quan sát thành cạnh ra tiếp theo để cực tiểu kỳ vọng thời gian đi

$$\pi^* = \arg\min_{\pi}\ \mathbb{E}\big[T^\pi\big], \qquad T^\pi = A(P^\pi,t_0) - t_0. \tag{2.10}$$

Chất lượng của một phương pháp trên một truy vấn được đo bằng *regret* so với oracle:

$$\text{Regret}(\pi) = 100\cdot\left(\frac{T^\pi}{T^{\text{oracle}}} - 1\right)\ (\%). \tag{2.11}$$

Biến thể theo rủi ro. Khi V_{real} là biến ngẫu nhiên với phân phối $\mathcal{D}$, ta có thể ưu tiên tuyến *tin cậy* bằng cách cực tiểu phân vị 90% thay vì kỳ vọng:

$$P^*_{0.9} = \arg\min_{P\in\mathcal{P}(s,d)} Q_{0.9}\big[A(P,t_0) - t_0\big], \qquad V_{\text{real}} \sim \mathcal{D}. \tag{2.12}$$

Chọn giờ xuất phát. Với bước chờ Δ phút, tối đa K lần chờ và trọng số chi phí chờ $w \in (0,1]$:

$$k^* = \arg\min_{k\in\{0,\dots,K\}} \Big[w\cdot k\Delta + T^{\text{oracle}}(t_0 + k\Delta)\Big]. \tag{2.13}$$

Với $w = 1$, đây đúng là "tổng thời gian chờ và đi"; $w < 1$ mô tả trường hợp chờ ở nhà/cơ quan ít tốn kém hơn ngồi trên xe.

Nhiều xe. Khi N xe được dẫn đường cùng lúc, tải dẫn đường $q_e(t)$ (xe/giờ) làm chậm cạnh theo hàm BPR của Cục Đường bộ Hoa Kỳ [10]:

$$\tau_e^{\text{load}}(t) = \tau_e(t)\left[1 + \alpha\left(\frac{q_e(t)}{c_e}\right)^{\beta}\right], \tag{2.14}$$

với c_e là năng lực thông hành của cạnh; mục tiêu hệ thống là cực tiểu tổng (hay trung bình) thời gian đi của các xe.

Đặc tính của bài toán.

Định lý 2.1 (**[4, 11]**) *Nếu mạng thoả FIFO* (2.6) *và* $\tau_e(t) > 0$, *bài toán* (2.8) *giải được trong thời gian đa thức bằng giải thuật gắn nhãn kiểu Dijkstra theo thời điểm đến* (*chứng minh ở Phần 4.3*).

Nhận xét 2.1 Khi mất tính FIFO và không cho phép chờ tại nút, đường tối ưu có thể không là đường đơn và tính chất cấu trúc con tối ưu bị phá vỡ [12]. Vì vậy trong mô phỏng chúng tôi *ép* tính FIFO (Phần 4.2.2).

Nhận xét 2.2 Bài toán trực tuyến (2.10) là một POMDP với không gian trạng thái liên tục và rất lớn (trường vận tốc trên m cạnh); không có lời giải dạng đóng. Các phương pháp trong đề tài là heuristic có cơ sở (tái lập kế hoạch) hoặc học từ dữ liệu (RL).

Nhận xét 2.3 Mục tiêu phân vị (2.12) *không cộng tính* theo cạnh: phân vị của tổng khác tổng các phân vị, nên bài toán mất tính chất cấu trúc con tối ưu và không giải trực tiếp được bằng Dijkstra. Đề tài dùng tập tuyến ứng viên (Yen [13]) rồi chọn theo phân vị ước lượng.

Nhận xét 2.4 Bài toán nhiều xe là một bài toán phân bổ giao thông: nếu mỗi xe tự chọn tuyến nhanh nhất cho mình, hệ thống hội tụ về cân bằng người dùng (nguyên lý Wardrop [14]), nói chung khác với tối ưu toàn hệ thống.

2.3 Khó khăn và thách thức

Độ phức tạp. Mạng đường Hà Đông sau làm sạch có $n = 3482$ nút và $m = 8944$ cạnh. Tìm kiếm phụ thuộc thời gian một lần có độ phức tạp $O((n+m)\log n)$ — rất nhanh; nhưng các bài toán xung quanh nhân chi phí đó lên nhiều lần: tái lập kế hoạch chạy lại tìm kiếm tại mỗi giao lộ (trung bình hàng chục lần mỗi chuyến), định tuyến theo rủi ro đánh giá nhiều ứng viên trên nhiều kịch bản, mô phỏng nhiều xe chạy hàng trăm tìm kiếm có tương tác, còn RL cần hàng trăm nghìn đến hàng triệu bước tương tác để học.

Các khía cạnh khiến bài toán khó.

(1) *Không có dữ liệu vận tốc thực* cho Hà Đông: phải xây dựng mô hình mô phỏng có cấu trúc và minh bạch giả định; mọi kết luận định lượng chỉ có giá trị trong mô phỏng.

(2) *Bảo đảm FIFO*: khi nội suy vận tốc theo phút, một đoạn đường dài có vận tốc tăng nhanh có thể làm $d\tau/dt < -1$; khi sự cố kết thúc, vận tốc nhảy vọt cũng phá vỡ FIFO.

(3) *Bất định và quan sát cục bộ*: dự báo sai có hệ thống (sự cố) chỉ được phát hiện khi xe đã đến gần.

(4) *Khó khăn riêng của RL*: phần thưởng thưa (chỉ biết đã đến đích ở cuối chuyến), tầm nhìn dài (một chuyến gồm hàng chục cạnh), 12,9% số nút là ngõ cụt, tập hành động thay đổi theo nút (cần mặt nạ hành động), và chính sách phải tổng quát hoá sang cặp điểm đi–đến, giờ xuất phát và vị trí sự cố chưa từng thấy.

(5) *Đánh giá công bằng*: các phương pháp phải chạy trên cùng tập kiểm tra, cùng môi trường thực tái lập theo seed, tách tập huấn luyện/kiểm định/kiểm tra theo cặp điểm đi–đến để tránh rò rỉ, và so sánh bằng kiểm định thống kê ghép cặp.

3 Nghiên cứu liên quan

3.1 Các phương pháp truyền thống

Đường đi ngắn nhất với trọng số tĩnh. Thuật toán Dijkstra [1] giải bài toán đường đi ngắn nhất một nguồn trên đồ thị có trọng số không âm bằng chiến lược tham lam: luôn "chốt" nút có nhãn khoảng cách nhỏ nhất trong hàng đợi ưu tiên. Với hàng đợi nhị phân, độ phức tạp là $O((n + m) \log n)$. Thuật toán A* [2] bổ sung một hàm heuristic $h(v)$ ước lượng khoảng cách còn lại tới đích; nếu h *chấp nhận được* (không vượt quá khoảng cách thật) thì A* vẫn tối ưu, và nếu h *nhất quán* thì mỗi nút được mở rộng tối đa một lần. Heuristic càng sát khoảng cách thật, số nút phải mở rộng càng ít.

Tăng tốc bằng tiền xử lý. Trên mạng đường cỡ quốc gia, người ta tiền xử lý đồ thị để truy vấn nhanh hơn nhiều bậc. ALT [15] chọn một số *điểm mốc* (landmark), tính sẵn khoảng cách tới/từ các điểm mốc và dùng bất đẳng thức

tam giác để xây heuristic chặt cho A*. Contraction Hierarchies [16] "co" lần lượt các nút ít quan trọng và thêm cạnh tắt, cho phép tìm kiếm hai chiều chỉ đi "lên" trong thứ bậc. Tổng quan đầy đủ về các kỹ thuật này có trong [17]. Thuật toán của Yen [13] liệt kê k đường đi không lặp ngắn nhất, thường dùng để đưa ra tuyến thay thế.

Đường đi ngắn nhất phụ thuộc thời gian. Cooke và Halsey [3] là những người đầu tiên đặt bài toán đường đi với thời gian di chuyển phụ thuộc thời điểm khởi hành, giải bằng quy hoạch động trên thời gian rời rạc. Dreyfus [4] nhận xét rằng có thể mở rộng trực tiếp Dijkstra bằng cách gắn nhãn *thời điểm đến* thay cho khoảng cách. Kaufman và Smith [11] chứng minh cách làm này cho kết quả đúng khi mạng thoả tính FIFO, trong khi Orda và Rom [12] phân tích trường hợp tổng quát, chỉ ra vai trò của việc cho phép hay cấm chờ tại nút. Ichoua, Gendreau và Potvin [18] đề xuất mô hình vận tốc thay đổi theo khoảng thời gian, trong đó thời gian qua cạnh được tính bằng cách tích phân vận tốc, nhờ đó FIFO được bảo đảm theo cấu trúc. Delling và Wagner [5] tổng quan các kỹ thuật định tuyến phụ thuộc thời gian, bao gồm TD-A* và các biến thể có tiền xử lý.

Tái lập kế hoạch trong môi trường thay đổi. Trong robot học, D* [19] và D* Lite [20] giải bài toán tìm đường khi chi phí cạnh chỉ được phát hiện dần trong quá trình di chuyển. Thay vì tìm lại từ đầu, D* Lite duy trì lời giải tìm kiếm ngược từ đích và chỉ cập nhật phần bị ảnh hưởng khi một số chi phí cạnh thay đổi, nhờ đó tiết kiệm đáng kể khi thay đổi mang tính cục bộ.

Heuristic tham lam. Một chiến lược đơn giản không cần mô hình toàn cục là luôn chọn cạnh ra hướng về đích nhất (theo góc hoặc theo khoảng cách chim bay giảm nhiều nhất). Chiến lược này nhanh nhưng dễ đi vào ngõ cụt; chúng tôi dùng nó làm mốc so sánh dưới cho các chính sách RL có cùng thông tin quan sát.

3.2 Các hướng tiếp cận hiện đại

Học tăng cường cho định tuyến. Boyan và Littman [21] đề xuất Q-routing — một trong những ứng dụng sớm nhất của RL cho định tuyến gói tin trong mạng có tải thay đổi. Q-learning dạng bảng [22] học hàm giá trị hành động bằng cập nhật thời gian–sai phân. Khi không gian trạng thái lớn, RL sâu dùng mạng nơ-ron xấp xỉ hàm giá trị (DQN [23]) hoặc trực tiếp tối ưu chính sách

(PPO [24]); các cài đặt chuẩn có trong thư viện Stable-Baselines3 [25]. Khi tập hành động hợp lệ thay đổi theo trạng thái (như số cạnh ra khác nhau ở mỗi giao lộ), *mặt nạ hành động* giúp gradient chính sách không lãng phí vào hành động không hợp lệ [26]. Định hình thưởng theo thế năng [27] giúp giảm độ thưa của phần thưởng mà không làm thay đổi chính sách tối ưu; học theo chương trình (curriculum learning) [28] bắt đầu từ nhiệm vụ dễ rồi tăng dần độ khó. Với quan sát một phần, mạng hồi quy LSTM [29] cho phép chính sách có bộ nhớ. Học bắt chước (behavior cloning) học chính sách từ quỹ đạo của chuyên gia; DAgger [30] khắc phục hiện tượng lệch phân phối bằng cách thu thập nhãn trên chính các trạng thái mà chính sách học được ghé thăm. Nền tảng chung của RL có trong [6].

Dự báo giao thông trên đồ thị. Mạng tích chập đồ thị (GCN) [31] tổng quát hoá phép tích chập lên dữ liệu có cấu trúc đồ thị bằng cách trộn đặc trưng của mỗi nút với các nút kề. DCRNN [7] mô hình hoá giao thông như một quá trình khuếch tán trên đồ thị và kết hợp với mạng hồi quy; STGCN [8] dùng các khối tích chập không gian–thời gian. Các mô hình này dự báo vận tốc trên mạng cảm biến; trong khung của đề tài, một mô hình như vậy có thể thay thế dự báo tĩnh V_{base} làm đầu vào cho TD-A*.

Định tuyến tính đến rủi ro và phân bổ giao thông. Khi thời gian đi là ngẫu nhiên, người lái thường quan tâm đến độ tin cậy (ví dụ thời gian đi ở phân vị 90%) hơn là giá trị trung bình. Khi nhiều người cùng chọn tuyến, lý thuyết phân bổ giao thông phân biệt cân bằng người dùng và tối ưu hệ thống theo nguyên lý Wardrop [14], với hàm trễ phổ biến là hàm BPR [10].

Công cụ. OSMnx [9] cho phép tải, làm sạch và phân tích mạng đường từ OpenStreetMap; Numba [32] biên dịch JIT mã Python số sang mã máy qua LLVM, giúp các vòng lặp tìm kiếm chạy nhanh gần bằng C.

3.3 Phân tích điểm mạnh / hạn chế

Bảng 3.1 tóm tắt so sánh định tính giữa các họ phương pháp, dựa trên tài liệu và bản chất thuật toán.

Bảng 3.1: So sánh định tính các họ phương pháp tìm đường.

Họ phương pháp	**Điểm mạnh**	**Hạn chế**
Dijkstra / A* tĩnh	Đơn giản, tối ưu với trọng số cố định, rất nhanh	Bỏ qua biến thiên vận tốc theo giờ
TD-Dijkstra / TD-A*	Tối ưu khi mạng thoả FIFO, thời gian đa thức	Cần mô hình vận tốc tương lai; nhạy với dự báo sai
ALT, Contraction Hierarchies	Truy vấn rất nhanh trên mạng lớn	Cần tiền xử lý; bản phụ thuộc thời gian phức tạp
Replan, D* Lite	Thích nghi với quan sát mới trong khi đi	Chi phí tìm kiếm lặp; D* Lite cần chi phí tĩnh giữa các lần cập nhật
Dự báo GNN	Lan truyền thông tin từ cảm biến sang cạnh chưa quan sát	Cần dữ liệu huấn luyện; chỉ có ích khi nhiễu có tương quan
Định tuyến theo rủi ro	Giảm đuôi phân phối thời gian đi	Mục tiêu không cộng tính; tốn nhiều mẫu
RL chọn từng cạnh	Không cần mô hình chuyển trạng thái tường minh	Khám phá khó, khái quát kém, không bảo đảm tới đích
RL kết hợp tìm kiếm	Giữ bảo đảm tới đích và chất lượng của tìm kiếm	Không gian hành động hẹp nên lợi ích có thể nhỏ

Khoảng trống nghiên cứu. Nhiều công trình đánh giá RL cho định tuyến trên lưới tổng hợp, hoặc không so sánh với TD-A* kết hợp tái lập kế hoạch trong cùng một môi trường; các kết quả vì vậy khó so sánh và dễ đánh giá quá cao vai trò của RL. Đề tài hướng tới lấp khoảng trống đó ở quy mô một quận của Việt Nam: (i) dùng mạng đường thật từ OpenStreetMap; (ii) so sánh mọi phương pháp trên *cùng* tập kiểm tra, *cùng* môi trường thực tái lập theo seed, *cùng* chỉ số và kiểm định thống kê ghép cặp; (iii) phân tích có hệ thống các cải tiến RL phổ biến và trình bày trung thực cả những kết quả âm.

4 Phương pháp đề xuất

4.1 Ý tưởng tổng quát

Chúng tôi tách bài toán thành ba tầng độc lập, giao tiếp với nhau qua một giao diện duy nhất là *hàm thời gian qua cạnh* $\tau(e, t)$:

(1) **Tầng môi trường.** Đồ thị đường từ OpenStreetMap; mô hình vận tốc 24 khung giờ V_{base} (vai trò "dự báo"); môi trường thực V_{real} có nhiễu tương quan và sự cố, tái lập được theo seed của từng truy vấn.

(2) **Tầng tác nhân ra quyết định.** Các thuật toán tìm kiếm (Dijkstra, A*, TD-Dijkstra, TD-A*), các cơ chế tái lập kế hoạch, dự báo GCN, định tuyến theo rủi ro và các chính sách RL. Mọi tác nhân chỉ "nhìn thấy" môi trường qua $\tau(e, t)$ của mô hình mà nó được phép biết (dự báo, dự báo cộng quan sát, hay môi trường thực đối với oracle).

(3) **Tầng đánh giá.** Mọi tác nhân được chạy trên cùng tập truy vấn kiểm tra cố định, trong cùng V_{real}, và được so sánh với oracle bằng các chỉ số thống nhất cùng kiểm định thống kê ghép cặp.

Cách tách này cho phép thay thế từng thành phần (ví dụ thay V_{base} mô phỏng bằng dự báo từ dữ liệu thật) mà không phải viết lại thuật toán. Sơ đồ khối của toàn hệ thống được trình bày ở Hình 4.5 (Mục 4.4).

4.2 Chi tiết thuật toán / mô hình

4.2.1 Xây dựng đồ thị từ OpenStreetMap

Xác định ranh giới. Ranh giới quận Hà Đông được lấy bằng dịch vụ geocode Nominatim. Do Hà Nội bỏ cấp quận từ ngày 01/7/2025, truy vấn "Hà Đông" có thể chỉ trả về *phường* Hà Đông mới (khoảng 9 km^2) thay vì quận cũ (khoảng 49 km^2). Chương trình vì vậy kiểm tra diện tích vùng trả về; nếu nhỏ hơn 20 km^2 thì lần lượt dùng: hợp của 5 phường mới tạo nên quận cũ (Hà Đông, Dương Nội, Yên Nghĩa, Phú Lương, Kiến Hưng), ranh giới đã lưu từ lần chạy trước, và cuối cùng là một hình chữ nhật bao. Vùng đệm 500 m được thêm vào để giữ các tuyến ra/vào quận.

Tải và làm sạch. Mạng đường dành cho ô tô được tải qua OSMnx [9]; chương trình thử lần lượt ba máy chủ Overpass (nếu máy chủ trước lỗi hoặc quá hạn thì chuyển sang máy chủ kế tiếp), rồi lưu bản sao cục bộ để các lần sau chạy không cần mạng. Đồ thị thô có 3519 nút và 9063 cạnh. Quá trình làm sạch gồm: bỏ 9 cạnh tự vòng; gộp 52 cạnh song song (giữ cạnh ngắn nhất); giữ thành phần liên thông mạnh lớn nhất (bỏ 37 nút không đi tới/đi về được). Kết quả: 3482 nút, 8944 cạnh, tổng chiều dài 944,5 km, chiều dài cạnh trung bình 106 m, bậc ra lớn nhất 5 và trung bình 2,57. Việc gộp cạnh song song theo chiều dài là một phép xấp xỉ vì cạnh ngắn hơn chưa chắc nhanh hơn ở mọi thời điểm. Chúng tôi đã đối chiếu 52 cặp bị gộp: ở 50 cặp, cạnh được giữ vừa ngắn hơn vừa cùng nhóm đường với vận tốc tự do không thấp hơn nên trội

hơn về thời gian trong mô hình; ở 2 cặp còn lại cạnh được giữ ngắn hơn và thuộc nhóm đường cao hơn (vận tốc tự do cao hơn). Do đó trong mô hình vận tốc của đề tài, phép gộp hầu như không loại mất tuyến nhanh hơn, ngoại trừ ảnh hưởng của nhiễu riêng từng cạnh và hệ số điểm nóng; ảnh hưởng này chưa được đánh giá riêng và là một hạn chế.

Chuẩn hoá thuộc tính. Thẻ `highway` được gom về năm nhóm: *trunk* (gồm cả motorway), *primary*, *secondary*, *tertiary* và *residential* (gồm các loại còn lại). Chỉ 6,5% số cạnh có thẻ `maxspeed`; các giá trị được phân tích từ nhiều định dạng ("50", "50 mph", danh sách) và giá trị thiếu được điền theo nhóm đường (trunk 60, primary 50, secondary 40, tertiary 30, residential 20 km/h). Vận tốc tự do được lấy bằng 90% vận tốc tối đa. Để heuristic ở các mục sau luôn chấp nhận được, chiều dài mỗi cạnh được ép không nhỏ hơn khoảng cách chim bay giữa hai đầu mút.

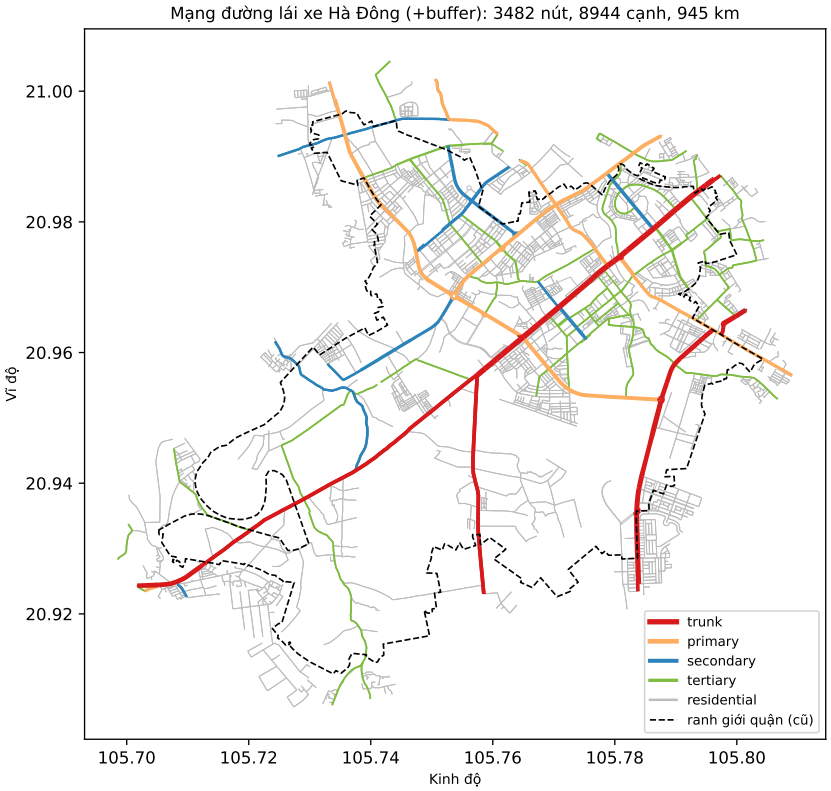
Biểu diễn CSR. Các cạnh được sắp theo nút đầu, và các cạnh ra của nút u là đoạn

$$\mathrm{out}(u) = \{\, \texttt{out_edges}[k] : \texttt{out_ptr}[u] \le k < \texttt{out_ptr}[u+1] \,\}, \tag{4.1}$$

nên việc duyệt cạnh ra là truy cập bộ nhớ liên tục, phù hợp cho cả vòng lặp Python lẫn mã biên dịch Numba. Phân bố loại đường được cho ở Bảng 4.1 và bản đồ ở Hình 4.1.

Bảng 4.1: Phân bố loại đường của đồ thị Hà Đông (sau làm sạch).

Nhóm đường	Số cạnh	Chiều dài (km)	Tỉ lệ (%)
trunk	291	44,4	4,7
primary	337	42,5	4,5
secondary	244	33,5	3,5
tertiary	867	106,2	11,2
residential	7205	717,9	76,0
Tổng	8944	944,5	100,0



Hình 4.1: Mạng đường lái xe quận Hà Đông (cộng vùng đệm 500 m) theo nhóm đường; nét đứt là ranh giới quận cũ.

4.2.2 Mô hình vận tốc 24 khung giờ

Với mỗi cạnh e và mỗi khung giờ $h \in \{0, 1, \ldots, 23\}$, vận tốc nền được xác định bởi một *mức ùn* $c(e,h) \in [0, c_{\max}]$:

$$v(e,h) = \max\Big(v_{\text{free}}(e)\big(1 - c(e,h)\big),\ v_{\min}\Big), \tag{4.2}$$

$$c(e,h) = \text{clip}\Big(\, p(h) \cdot s(g_e) \cdot \eta(e,h) \cdot \delta(e,h) + \xi(e,h),\ 0,\ c_{\max}\Big), \tag{4.3}$$

với $c_{\max} = 0{,}85$ và $v_{\min} = 5$ km/h. Các thành phần được thiết kế để mỗi thành phần phản ánh một hiện tượng giao thông có thật:

Profile theo giờ $p(h)$ là tổng các hàm Gaussian *tuần hoàn* chu kỳ 24 giờ, bảo đảm tính lặp lại hằng ngày $(p(0) = p(24))$:

$$p(h) = b + \sum_{j} a_j \sum_{k \in \{-1,0,1\}} \exp\left(-\frac{(h - \mu_j + 24k)^2}{2\sigma_j^2}\right), \tag{4.4}$$

với các đỉnh sáng ($\mu = 8$), trưa ($\mu = 12{,}5$), chiều ($\mu = 18$), tối ($\mu = 21$) và một "trũng" ban đêm (biên độ âm, $\mu = 3$); tham số đầy đủ ở Phụ lục.

Độ nhạy theo loại đường $s(g)$ phản ánh việc trục chính chịu ùn nặng hơn đường nhánh: trunk 1,0; primary 0,95; secondary 0,8; tertiary 0,65; residential 0,4.

Hệ số trục nóng $\eta(e, h)$ lấy từ tệp `hotspots.yaml` (Phụ lục): mỗi điểm nóng có hệ số nhân và khung giờ ảnh hưởng; cạnh được khớp theo tên đường không dấu (loại trừ các ngõ/ngách mang tên trục), theo mã đường (ví dụ QL.6) hoặc theo bán kính quanh toạ độ nút giao (Cầu Am, Mai Lĩnh, Bến xe Yên Nghĩa).

Hệ số hướng $\delta(e, h)$ làm ùn nặng hơn theo hướng vào trung tâm buổi sáng và hướng ra buổi chiều:

$$\delta(e, h) = 1 + \beta\, a_e \left(w_{\text{sáng}}(h) - w_{\text{chiều}}(h)\right), \qquad a_e = \cos\angle\big(\vec{e},\, \vec{c} - \vec{m}_e\big), \tag{4.5}$$

trong đó $\vec{c}$ là toạ độ Ngã Tư Sở (tâm tham chiếu), $\vec{m}_e$ là trung điểm cạnh, $w_{\text{sáng}}, w_{\text{chiều}}$ là các Gaussian tuần hoàn quanh 8h và 18h, $\beta = 0{,}3$.

Nhiễu không gian $\xi(e, h)$ được tạo bằng cách làm mượt nhiễu Gaussian k lần qua ma trận kề cạnh–cạnh chuẩn hoá theo hàng $\hat{A}$ (hai cạnh kề nếu chung đầu mút), làm mượt thêm theo giờ bằng nhân $(0{,}25;\ 0{,}5;\ 0{,}25)$ vòng 24 giờ, sau đó chuẩn hoá về độ lệch chuẩn σ_ξ:

$$\Xi^{(k)} = \hat{A}^{\,k}\, \Xi^{(0)}, \qquad \Xi^{(0)}_{e,h} \sim \mathcal{N}(0, 1), \tag{4.6}$$

cộng thêm một thành phần nhỏ phụ thuộc "seed ngày" để mỗi ngày khác nhau nhưng vẫn cùng quy luật.

Nội suy theo phút. Với t phút, đặt $h = \lfloor (t \bmod 1440)/60 \rfloor$ và $\phi = ((t \bmod 1440) - 60h)/60$; vận tốc được nội suy tuyến tính (vòng 24 giờ):

$$v_e(t) = (1 - \phi)\, v(e, h) + \phi\, v\big(e, (h + 1) \bmod 24\big). \tag{4.7}$$

Bảo đảm FIFO cho vận tốc nền. Trong một khung giờ (60 phút), nếu vận tốc (tính bằng m/phút) tăng tuyến tính từ v_ℓ lên v_u thì $\tau_e(t) = L_e/v_e(t)$ giảm với tốc độ lớn nhất tại đầu mút có vận tốc thấp:

$$\max_t \left(-\frac{d\tau_e}{dt}\right) = \frac{L_e\,(v_u - v_\ell)}{60\, v_\ell^2}. \tag{4.8}$$

Chúng tôi yêu cầu đại lượng này không vượt quá $\kappa = 0{,}9 < 1$ (biên an toàn cho điều kiện (2.7)). Nếu vi phạm, vận tốc đầu mút thấp được nâng lên giá

trị nhỏ nhất thoả mãn, tức nghiệm dương của

$$60\kappa\, x^2 + L_e\, x - L_e\, v_u = 0 \implies x = \frac{-L_e + \sqrt{L_e^2 + 240\kappa L_e v_u}}{120\kappa}, \tag{4.9}$$

và thủ tục lặp tới khi mọi đoạn thoả mãn (Bổ đề 4.1). Với V_{base} của Hà Đông, độ dốc lớn nhất đo được là 0,525 nên không ô nào cần sửa.

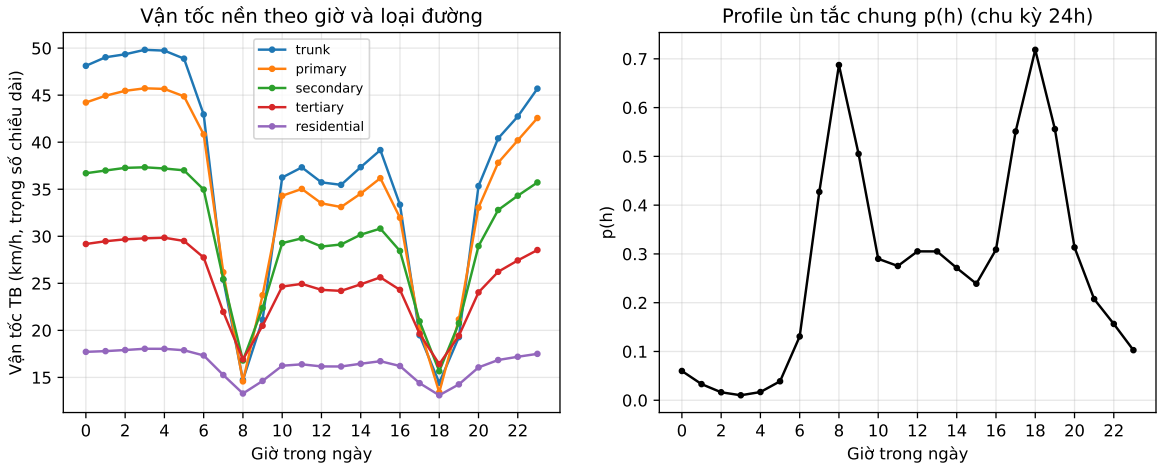
Sự cố. Một sự cố trên cạnh e bắt đầu lúc t_s, kéo dài D phút, mức độ $\rho \in [0{,}1; 0{,}4]$, nhân vận tốc với hệ số

$$f(t) = \begin{cases} 1 - (1-\rho)\dfrac{t - t_s}{r_{\text{in}}}, & t_s \le t < t_s + r_{\text{in}}, \\ \rho, & t_s + r_{\text{in}} \le t \le t_s + D, \\ \rho + (1-\rho)\dfrac{t - t_s - D}{r_{\text{out}}}, & t_s + D < t < t_s + D + r_{\text{out}}, \\ 1, & \text{ngược lại}, \end{cases} \tag{4.10}$$

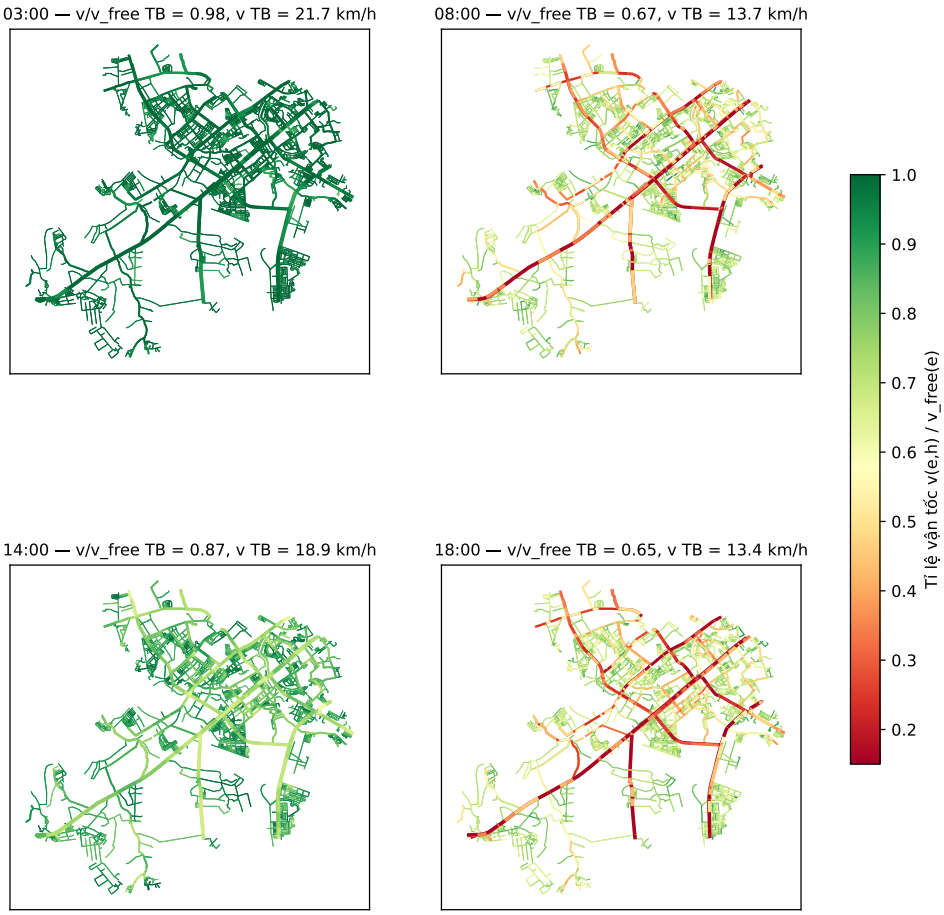
với $r_{\text{in}} = 5$ phút (dốc vào) và $r_{\text{out}} = 15$ phút (giải toả). Khi sự cố kết thúc, vận tốc tăng nhanh có thể phá vỡ FIFO. Vì vậy hàm đến của cạnh bị sự cố được tính trên lưới 1 phút rồi *FIFO hoá*:

$$\tilde{a}_e(t) = \min_{t' \ge t} a_e(t'), \tag{4.11}$$

và nội suy tuyến tính giữa các điểm lưới. Về mặt vật lý, (4.11) tương ứng với việc xe đến cạnh sớm "đợi" ngầm để không về muộn hơn xe đến sau; Mệnh đề 4.2 chứng minh tính FIFO tuyệt đối của kết quả.



Hình 4.2: Vận tốc nền trung bình theo giờ và nhóm đường (trái); profile ùn tắc chung $p(h)$ (phải).



Hình 4.3: Tỉ lệ v/v_{free} trên toàn mạng lúc 3h, 8h, 14h và 18h.

Hình 4.2 và Hình 4.3 cho thấy mô hình tái hiện đúng các hiện tượng mong muốn: vận tốc trung bình (trọng số theo chiều dài) là 22,8 km/h lúc 3h, 13,9 km/h lúc 8h, 19,7 km/h lúc 14h và 13,6 km/h lúc 18h; vào giờ cao điểm các trục chính chuyển sang màu đỏ.

4.2.3 Môi trường thực với nhiễu tương quan

Môi trường thực của mỗi truy vấn được sinh từ vận tốc nền và một trường nhiễu nhân:

$$V_{\text{real}} = \mathcal{F}\Big(V_{\text{base}} \odot \exp\big(\sigma Z\big)\Big), \tag{4.12}$$

trong đó $\mathcal{F}$ là thủ tục sửa FIFO (4.9), $\odot$ là tích từng phần tử, σ là mức nhiễu của truy vấn (nhận một trong các giá trị $0{,}05$; $0{,}15$; $0{,}30$). Trường Z có phân phối biên chuẩn tắc $\mathcal{N}(0,1)$ nên hệ số $\varepsilon = e^{\sigma Z}$ tuân theo phân phối LogNormal$(0,\sigma)$;

nhưng khác với nhiễu độc lập, Z có *tương quan không gian–thời gian*:

$$Z_{\cdot,h} = \rho\, Z_{\cdot,h-1} + \sqrt{1-\rho^2}\; \hat{A}^{\,k} W_{\cdot,h}, \qquad W_{e,h} \sim \mathcal{N}(0,1), \tag{4.13}$$

sau đó chuẩn hoá và trộn với một phần nhiễu độc lập:

$$Z \leftarrow \sqrt{1-\gamma}\; Z + \sqrt{\gamma}\; U, \qquad U_{e,h} \sim \mathcal{N}(0,1), \tag{4.14}$$

với $\rho = 0{,}8$, $k = 4$, $\gamma = 0{,}3$. Đo trên trường mẫu, tương quan giữa hai giờ liền kề là 0,56 và giữa hai cạnh nối tiếp là 0,61. Tương quan này là điều kiện để quan sát ở hiện tại và ở lân cận mang thông tin về tương lai gần và về các cạnh chưa quan sát — tiền đề của dự báo ngắn hạn ở Mục 4.2.6.

4.2.4 Tìm kiếm phụ thuộc thời gian và heuristic

TD-Dijkstra gán cho mỗi nút nhãn $\mathrm{arr}(v)$ là thời điểm đến sớm nhất đã biết. Khi lấy nút u ra khỏi hàng đợi, mỗi cạnh $e = (u, v)$ được "nới lỏng":

$$\mathrm{arr}(v) \leftarrow \min\Big(\mathrm{arr}(v),\; \mathrm{arr}(u) + \tau_e\big(\mathrm{arr}(u)\big)\Big). \tag{4.15}$$

TD-A* ưu tiên các nút theo khoá

$$f(v) = \mathrm{arr}(v) + h(v), \tag{4.16}$$

với $h(v)$ là cận dưới của thời gian còn lại tới đích (Thuật toán 1). Chúng tôi cài đặt ba heuristic:

Heuristic chim bay. Với $v_{\max}$ là vận tốc lớn nhất toàn cục của mô hình (54,0 km/h với V_{base}):

$$h_{\text{eu}}(v) = 0{,}995 \cdot \frac{\mathrm{dist}(v, d)}{v_{\max}}. \tag{4.17}$$

Heuristic cận dưới chính xác (LB). Với mỗi cạnh, thời gian nhỏ nhất qua cạnh trong mọi khung giờ là

$$\tau_{\min}(e) = \frac{L_e}{\max_h v(e,h)} \le \tau_e(t) \quad \forall t, \tag{4.18}$$

(sự cố chỉ làm chậm nên bất đẳng thức vẫn đúng), và heuristic là khoảng cách ngắn nhất trên đồ thị trọng số $\tau_{\min}$:

$$h_{\text{LB}}(v) = d_{\tau_{\min}}(v, d), \tag{4.19}$$

tính bằng một lần Dijkstra ngược từ đích. Đây là heuristic tĩnh chặt nhất có thể xây từ cận dưới theo từng cạnh.

Heuristic ALT [15]. Chọn $\mathcal{L}$ gồm 8 điểm mốc theo chiến lược "điểm xa nhất" trên đồ thị $\tau_{\min}$, tiền tính $d(\ell, \cdot)$ và $d(\cdot, \ell)$; heuristic theo bất đẳng thức tam giác:

$$h_{\mathrm{ALT}}(v) = \max_{\ell \in \mathcal{L}} \max\Big(d(v,\ell) - d(d,\ell),\ d(\ell,d) - d(\ell,v),\ 0 \Big). \tag{4.20}$$

Biên dịch JIT. Cùng thuật toán TD-A* được viết lại cho Numba [32], chạy trực tiếp trên mảng CSR và ma trận vận tốc, cho kết quả và số nút mở rộng trùng khớp với bản Python (đã kiểm chứng bằng kiểm thử đơn vị). **Phạm vi hiệu lực của cận vận tốc.** Các heuristic chỉ chấp nhận được khi $v_{\max}$ (và $\tau_{\min}$) là cận của *chính mô hình thời gian mà lần tìm kiếm đang dùng*. Nhiễu nhân $e^{\sigma Z}$ có thể đưa vận tốc của V_{real} vượt V_{base}; thủ tục $\mathcal{F}$ chỉ nâng vận tốc thấp lên không quá vận tốc đầu mút cao hơn nên không làm tăng cực đại, còn sự cố chỉ làm chậm. Vì vậy: (i) tìm kiếm trên dự báo (plan-once và mọi heuristic LB, ALT) dùng cận của V_{base}; (ii) oracle dùng $v_{\max}$ tính lại trên chính V_{real} của từng truy vấn, và không dùng LB hay ALT; (iii) replan, D* Lite, RL lai và replan + GCN lập kế hoạch trên τ^{obs} hoặc vận tốc dự báo $V_{\text{base}}e^{\hat{r}}$ vốn có thể nhanh hơn V_{base}, nên chi phí cạnh bị chặn dưới bởi $L_e/v_{\max}$ của dự báo như ở (4.22). Cận chặn này là điều kiện để Mệnh đề 4.1 áp dụng; nếu không có nó thì phải dùng $h = 0$ (TD-Dijkstra).

Contraction Hierarchies không được cài đặt: ở quy mô vài nghìn nút, TD-A* biên dịch đã chạy dưới một mili-giây mỗi truy vấn; CH chỉ thật sự cần thiết khi mở rộng ra toàn thành phố.

4.2.5 Tái lập kế hoạch

Replan. Tại mỗi giao lộ u ở thời điểm t, xe đo độ lệch giữa thời gian thực và dự báo cho mọi cạnh trong bán kính $r = 400$ m:

$$\delta_e = \tau_e^{\text{real}}(t) - \tau_e^{\text{base}}(t), \qquad e \in \mathcal{N}_r(u), \tag{4.21}$$

ghi nhớ các độ lệch đã đo, giả định chúng *duy trì* trong tương lai gần và lập lại kế hoạch bằng TD-A* trên mô hình

$$\tau_e^{\text{obs}}(t') = \max\Big(\tau_e^{\text{base}}(t') + \delta_e,\ \frac{L_e}{v_{\max}} \Big). \tag{4.22}$$

Cộng một hằng số vào hàm thời gian giữ nguyên tính FIFO, còn cận dưới $L_e/v_{\max}$ giữ heuristic chim bay chấp nhận được. Xe đi cạnh đầu tiên của kế hoạch mới rồi lặp lại (Thuật toán 2).

Replan lười. Chỉ chạy lại tìm kiếm khi có ít nhất một cạnh quan sát mà độ lệch thay đổi đáng kể so với lúc lập kế hoạch gần nhất:

$$\exists\, e \in \mathcal{N}_r(u): \quad \left|\delta_e^{\text{mới}} - \delta_e^{\text{lúc lập}}\right| > \theta\, \tau_e^{\text{base}}(t), \tag{4.23}$$

với $\theta = 0{,}15$; ngược lại xe tiếp tục đi theo kế hoạch cũ.

D* Lite với chi phí snapshot. D* Lite [20] tìm kiếm ngược từ đích và duy trì hai giá trị cho mỗi nút: $g(v)$ và giá trị nhìn trước

$$\text{rhs}(v) = \min_{e=(v,w)} \big(c(e) + g(w)\big), \qquad \text{rhs}(d) = 0, \tag{4.24}$$

cùng khoá ưu tiên (với s là vị trí hiện tại và k_m là bù trừ tích luỹ khi xe di chuyển)

$$\text{key}(v) = \Big(\min\big(g(v), \text{rhs}(v)\big) + h(s,v) + k_m,\ \min\big(g(v), \text{rhs}(v)\big)\Big). \tag{4.25}$$

Vì D* Lite đòi hỏi chi phí tĩnh, ta dùng chi phí *snapshot* $c(e) = \tau_e^{\text{obs}}(t_{\text{snap}})$; giữa hai lần dựng lại, chỉ các cạnh có quan sát mới được cập nhật và D* Lite chỉ sửa phần lời giải bị ảnh hưởng. Toàn bộ chi phí được dựng lại sau mỗi 15 phút di chuyển. Đánh đổi: nhanh hơn TD-A* lặp nhưng bỏ qua biến thiên vận tốc trong tương lai gần.

4.2.6 Dự báo ngắn hạn bằng mạng tích chập đồ thị

Giả định có 15% số cạnh được gắn cảm biến (hoặc có xe thăm dò), gồm mọi trục trunk/primary và một phần ngẫu nhiên các cạnh khác (tổng cộng 1341 cạnh). Tại thời điểm t, ta quan sát log-tỉ số vận tốc

$$r_e(t) = \log \frac{v_e^{\text{real}}(t)}{v_e^{\text{base}}(t)} = \log \frac{\tau_e^{\text{base}}(t)}{\tau_e^{\text{real}}(t)} \tag{4.26}$$

trên các cạnh có cảm biến và các cạnh trong bán kính quan sát. Đặc trưng đầu vào của cạnh e là $x_e = [\, r_e \mathbf{1}_e,\ \mathbf{1}_e,\ \text{onehot}(g_e),\ \sin\omega t,\ \cos\omega t,\ c(e,h)\,]$ với $\mathbf{1}_e$ là cờ "đã quan sát". Mạng tích chập đồ thị [31] trên đồ thị cạnh–cạnh gồm

$$H^{(0)} = \text{ReLU}\big(XW_0\big), \qquad H^{(\ell+1)} = \text{ReLU}\Big(\hat{A} H^{(\ell)} W_1^{(\ell)} + H^{(\ell)} W_2^{(\ell)}\Big), \tag{4.27}$$

với 3 lớp ẩn kích thước 32, đầu ra $\hat{y}_e \in \mathbb{R}^2$ là log-tỉ số dự đoán tại hai mốc giờ h và $h+1$. Hàm mất mát là sai số bình phương trung bình trên mọi cạnh:

$$\mathcal{L}_{\text{GCN}} = \frac{1}{2m} \sum_{e \in E} \left\| \hat{y}_e - y_e \right\|_2^2, \tag{4.28}$$

huấn luyện bằng Adam trên các "ngày" mô phỏng có seed độc lập với tập kiểm tra. Với các mốc giờ xa hơn, dự báo tắt dần theo hệ số tự tương quan:

$$\hat{r}_e(h+k) = \rho^{\,k-1}\, \hat{y}_{e,2}, \qquad k \geq 2, \tag{4.29}$$

rồi ma trận vận tốc dự báo $V_{\text{base}} \odot e^{\hat{r}}$ được đưa vào TD-A*. Hai cách dùng: *plan-once + GCN* (dự báo một lần lúc xuất phát) và *replan + GCN* (cập nhật GCN mỗi 5 phút; các cạnh vừa quan sát vẫn dùng độ lệch đo trực tiếp (4.21)). Đối chứng *plan-once + cảm biến* chỉ dùng độ lệch trên chính các cạnh có cảm biến mà không lan truyền sang cạnh khác.

4.2.7 Định tuyến theo rủi ro (P90)

Một "ngân hàng kịch bản" gồm $M = 30$ ma trận vận tốc được sinh từ cùng mô hình nhiễu (4.12) với seed độc lập với tập kiểm tra. Tập ứng viên $\mathcal{C}$ gồm 6 tuyến của thuật toán Yen theo thời gian qua cạnh tại giờ xuất phát, cộng tuyến TD-A* theo dự báo. Phân vị 90% của mỗi ứng viên được ước lượng bằng phân vị thực nghiệm trên các kịch bản và chọn

$$\hat{P} = \arg\min_{P \in \mathcal{C}} \widehat{Q}_{0.9}\left\{ T^{(j)}(P, t_0) \right\}_{j=1}^{M}, \tag{4.30}$$

trong đó $T^{(j)}(P, t_0)$ là thời gian đi tuyến P trong kịch bản j, được tính vector hoá đồng thời cho cả M kịch bản.

4.2.8 Học tăng cường

Môi trường. Môi trường chuẩn Gymnasium: tác tử đứng tại một nút và chọn một trong $K = 5$ khe cạnh ra (khe trống bị che bằng mặt nạ). Mỗi tập lấy một cặp điểm đi–đến của tập huấn luyện, với giờ xuất phát, seed nhiễu và sự cố được sinh *mới* để tác tử không học thuộc. Quan sát *cục bộ* gồm vị trí tương đối tới đích (chuẩn hoá 8 km), khoảng cách chim bay, sin / cos của giờ, tỉ lệ số bước đã dùng; và với mỗi khe cạnh ra: cờ hợp lệ, vận tốc quan sát hiện tại

(nhiễu 5%) chia 60 km/h, chiều dài chia 500 m, cosin góc giữa cạnh và hướng tới đích, cờ "nút cuối đã thăm".

Phần thưởng. Khi đi cạnh e mất τ phút từ nút u tới nút u':

$$\begin{aligned} r = -\tau + \lambda\, F(u,u') + R_{\text{goal}}\,\mathbf{1}[u' = d] \\ - R_{\text{rev}}\,\mathbf{1}[u' \text{ đã thăm}] - R_{\text{out}}\,\mathbf{1}[\text{quá số bước}], \end{aligned} \tag{4.31}$$

với $R_{\text{goal}} = 10$, $R_{\text{rev}} = 1$, $R_{\text{out}} = 10$, giới hạn số bước bằng $3\times$ số cạnh của tuyến tham chiếu cộng 20. Thành phần định hình F có hai dạng: theo khoảng cách chim bay (quy ra phút ở 30 km/h), hoặc *theo thế năng cost-to-go* [27]:

$$F(u,u') = \Phi(u') - \Phi(u), \qquad \Phi(u) = -\,\text{ctg}_{\text{tự do}}(u), \tag{4.32}$$

trong đó $\text{ctg}_{\text{tự do}}(u)$ là thời gian tự do ngắn nhất từ u tới đích. Thông tin toàn cục này chỉ nằm trong *phần thưởng* lúc huấn luyện; chính sách không quan sát được nó (Mệnh đề 4.3).

Thuật toán học. MaskablePPO (sb3-contrib) tối ưu hàm mục tiêu cắt xén của PPO [24]:

$$\begin{aligned} \mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t\Big[\min\big(\varrho_t(\theta)\hat{A}_t,\ \text{clip}(\varrho_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\big)\Big], \\ \varrho_t(\theta) = \frac{\pi_\theta(a_t \mid o_t)}{\pi_{\theta_{\text{old}}}(a_t \mid o_t)}, \end{aligned} \tag{4.33}$$

với $\hat{A}_t$ là ước lượng lợi thế GAE, $\epsilon = 0{,}2$, hệ số chiết khấu $0{,}995$; xác suất của hành động bị che bằng mặt nạ được đặt bằng 0 trước khi chuẩn hoá [26]. Huấn luyện theo chương trình ba mức [28]: mức 1 (cặp điểm gần dưới 2,5 km, không nhiễu) tới 20% số bước; mức 2 (mọi cặp, có nhiễu) tới 50%; mức 3 (thêm sự cố).

Các biến thể (Bảng 4.2):

- *RL cục bộ* — đúng đặc tả ban đầu: quan sát cục bộ, định hình theo khoảng cách chim bay.
- *RL + ctg (quan sát)* — thí nghiệm đối chứng: thêm cost-to-go tự do (thông tin toàn cục tĩnh) vào quan sát.
- *RL + định hình ctg* — quan sát cục bộ, định hình thưởng theo (4.32).
- *RL cây-GNN* — quan sát cây lân cận 3 bước ($K + K^2 + K^3$ khe, mỗi khe thêm cờ ngõ cụt, cờ quay đầu, tiến độ tới đích). Bộ trích đặc trưng truyền

thông điệp từ lá lên gốc với trọng số dùng chung giữa các khe cùng tầng:

$$\begin{aligned} m_D(j) &= \phi_D\big(x_D(j)\big), \\ m_d(j) &= \phi_d\Big(\big[\, x_d(j) \,\|\, \max_{c\in\mathrm{con}(j)} m_{d+1}(c) \,\big]\Big), \quad d = D-1,\dots,1, \end{aligned} \tag{4.34}$$

và vector đặc trưng đưa vào chính sách là $[\psi(x_{\text{glob}}),\, m_1(1),\dots,m_1(K)]$ — mỗi nhánh tầng 1 ứng với một hành động, nên chính sách "nhìn" được phía sau mỗi cạnh ra tới D bước.

- *RL LSTM* — RecurrentPPO với LSTM [29] có 128 đơn vị ẩn. Vì sb3-contrib không hỗ trợ mặt nạ cho RecurrentPPO, hành động a được ánh xạ thành a mod $\deg^+(u)$.

- *RL cây-GNN + BC* — trước khi chạy PPO, chính sách được học bắt chước từ oracle. Dữ liệu thu theo kiểu DAgger nhẹ [30]: thực thi hành động ngẫu nhiên với xác suất 20%, còn nhãn luôn là cạnh tiếp theo của tuyến oracle tính lại từ trạng thái hiện tại. Hàm mất mát là log-likelihood âm:

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{(o,a^*,\mu)\in\mathcal{D}} \log \pi_\theta\big(a^* \mid o, \mu\big), \tag{4.35}$$

  với μ là mặt nạ hành động; sau đó tinh chỉnh bằng PPO với tốc độ học nhỏ hơn (10^{-4}).

- *RL lai* (*RL + tìm kiếm*) — hành động là hệ số $\beta \in \{0;\ 0{,}5;\ 1;\ 2;\ 4\}$ thể hiện mức tin vào quan sát; TD-A* lập kế hoạch trên

$$\tau_e^{(\beta)}(t) = \max\Big(\tau_e^{\text{base}}(t) + \beta\,\delta_e,\ \frac{L_e}{v_{\max}}\Big) \tag{4.36}$$

  và xe đi cạnh đầu tiên. $\beta = 1$ chính là replan, $\beta = 0$ là chỉ dùng dự báo, $\beta > 1$ là né vùng chậm mạnh tay hơn; quan sát gồm 12 đặc trưng tóm tắt (khoảng cách, giờ, thống kê độ lệch quan sát, độ trễ so với kế hoạch). Vì TD-A* luôn tìm được đường trên đồ thị liên thông mạnh, tác tử *luôn* tới đích.

Bảng 4.2: Các biến thể học tăng cường (mỗi biến thể huấn luyện với 3 seed).

Biến thể	**Quan sát**	**Thuật toán**	**Điểm khác biệt**
RL cục bộ	cục bộ (K cạnh ra)	MaskablePPO	đặc tả gốc, định hình chim bay
RL + ctg (quan sát)	cục bộ + cost-to-go	MaskablePPO	đối chứng có thông tin toàn cục
RL + định hình ctg	cục bộ	MaskablePPO	định hình thưởng theo thế năng
RL cây-GNN	cây 3 bước	MaskablePPO + GNN	quan sát rộng hơn
RL LSTM	cục bộ	RecurrentPPO	bộ nhớ (không có mặt nạ)
RL cây-GNN + BC	cây 3 bước	MaskablePPO + GNN	học bắt chước oracle trước
RL lai	12 đặc trưng tóm tắt	MaskablePPO	RL chọn β, TD-A* tìm đường

4.2.9 Chọn giờ xuất phát

Tác tử quyết định "đi ngay" hay "chờ thêm 10 phút" (tối đa 6 lần). Trạng thái gồm khung 30 phút trong ngày, số lần đã chờ, nhóm khoảng cách và nhóm mức ùn *dự báo* của chính cặp điểm đi–đến ($T^{\text{dự báo}}(t)/T^{\text{tự do}}$) — thông tin có sẵn tại thời điểm quyết định. Q-learning dạng bảng [22] cập nhật

$$Q(s,a) \leftarrow Q(s,a) + \alpha\Big[r + \gamma \max_{a'} Q(s',a') - Q(s,a)\Big], \tag{4.37}$$

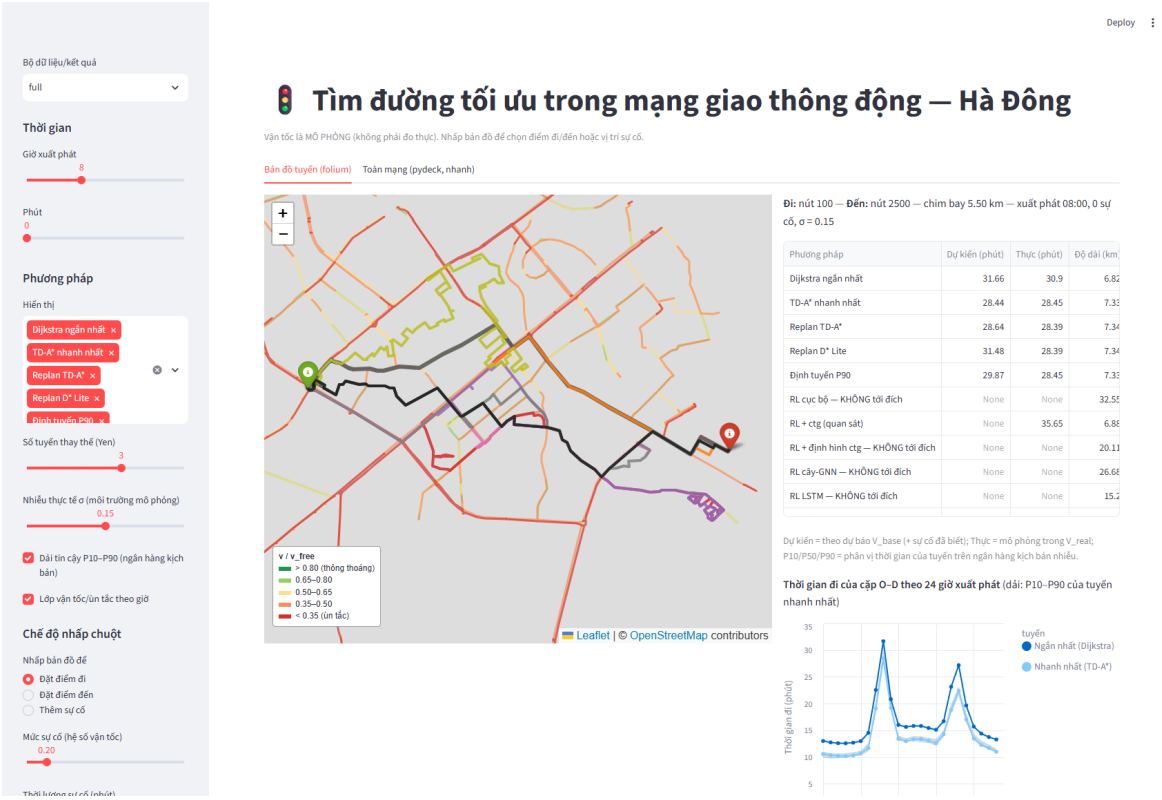
với phần thưởng $r = -w\Delta$ khi chờ và $r = -T^{\text{oracle}}(t)$ khi đi. Vì Q khởi tạo bằng 0 trong khi mọi phần thưởng đều âm, các ô ít được ghé sẽ trông "lạc quan"; khi ra quyết định chúng tôi chỉ tin Q ở những ô đã được cập nhật ít nhất 20 lần, ngược lại mặc định đi ngay.

4.2.10 Mô phỏng nhiều xe

Mỗi tác tử đại diện cho 20 xe, xuất phát ngẫu nhiên trong khung 7:30–8:00. Tải dẫn đường trên mỗi cạnh trong từng khung 15 phút làm chậm cạnh theo hàm BPR (2.14) với $\alpha = 0{,}5$, $\beta = 2$ và năng lực theo nhóm đường. Hai chiến lược: *dẫn đường giống nhau* (mọi xe chạy TD-A* trên dự báo, không biết xe khác) và *phối hợp tuần tự* (lập kế hoạch lần lượt theo giờ xuất phát, mỗi xe thấy tải của các xe đã lập trước). Thời gian đi thực tế được tính bằng lặp điểm bất động giữa tải và lịch trình trên các tuyến cố định.

4.2.11 Ứng dụng minh hoạ và đóng gói

Ứng dụng Streamlit (Hình 4.4) cho phép nhấp bản đồ để đặt điểm đi/đến hoặc vị trí sự cố, chọn giờ và phương pháp (Dijkstra, TD-A*, replan, D* Lite, P90 và các biến thể RL đã huấn luyện), hiển thị bảng thời gian dự kiến/thực tế cùng các phân vị P10/P50/P90 trên ngân hàng kịch bản, k tuyến thay thế, lớp màu vận tốc (gộp theo 5 lớp màu, có chú thích), đường cong thời gian đi theo 24 giờ xuất phát kèm dải P10–P90, và một thẻ vẽ toàn bộ 8944 cạnh bằng WebGL. Toàn bộ dự án được đóng gói bằng Docker (PyTorch bản CPU) và đã được kiểm tra chạy trong container.



Hình 4.4: Giao diện ứng dụng minh hoạ (chụp tự động; nền bản đồ không tải trong trình duyệt chạy ẩn).

4.3 Phân tích độ phức tạp / tính đúng đắn

Định lý 4.1 *Nếu mọi hàm đến a_e không giảm (FIFO) và $\tau_e(t) > 0$, TD-Dijkstra trả về thời điểm đến sớm nhất tại d khi xuất phát từ s lúc t_0.*

Chứng minh. Gọi $T^*(v)$ là thời điểm đến sớm nhất tại v. Trước hết, nhờ FIFO, mỗi tiền tố của một đường tối ưu có thể chọn là tối ưu: nếu đường tối ưu tới

v đi qua x ở thời điểm $t_x > T^*(x)$, thay tiền tố tới x bằng đường đến x lúc $T^*(x)$ rồi đi tiếp cùng dãy cạnh; do mọi a_e không giảm, thời điểm đến v không muộn hơn. Bây giờ quy nạp theo thứ tự lấy nút ra khỏi hàng đợi: giả sử mọi nút đã đóng có nhãn bằng T^*. Khi lấy u ra, xét đường tối ưu tới u và nút y đầu tiên trên đó chưa đóng, với nút liền trước x đã đóng. Khi đóng x, cạnh (x, y) đã được nới lỏng nên $\text{arr}(y) \le a_{xy}(T^*(x)) = T^*(y) \le T^*(u)$, bất đẳng thức cuối do $\tau > 0$. Vì u được chọn trước y nên $\text{arr}(u) \le \text{arr}(y) \le T^*(u)$; mặt khác $\text{arr}(u) \ge T^*(u)$ theo định nghĩa. Vậy $\text{arr}(u) = T^*(u)$. □

Mệnh đề 4.1 *Các heuristic h_{eu} (4.17), h_{LB} (4.19) và h_{ALT} (4.20) đều chấp nhận được và nhất quán: $h(u) \le \tau_e(t) + h(v)$ với mọi $e = (u, v)$ và mọi t. Do đó TD-A* trả về lời giải tối ưu và mỗi nút được mở rộng tối đa một lần.*

Chứng minh. Từ (4.18) và việc chiều dài cạnh được ép không nhỏ hơn khoảng cách hai đầu: $\tau_e(t) \ge \tau_{\min}(e) \ge L_e/v_{\max} \ge \text{dist}(u, v)/v_{\max}$. Với h_{eu}: bất đẳng thức tam giác cho $\text{dist}(u, d) \le \text{dist}(u, v) + \text{dist}(v, d)$. Với h_{LB}: theo định nghĩa khoảng cách ngắn nhất, $d_{\tau_{\min}}(u, d) \le \tau_{\min}(e) + d_{\tau_{\min}}(v, d)$. Với h_{ALT}: mỗi số hạng trong (4.20) là cận dưới nhất quán theo bất đẳng thức tam giác trên đồ thị $\tau_{\min}$ [15], và cực đại của các heuristic nhất quán vẫn nhất quán. Hệ số an toàn nhỏ hơn 1 chỉ làm h nhỏ đi. Các bất đẳng thức trên được hiểu theo mô hình thời gian mà lần tìm kiếm đang dùng (xem "Phạm vi hiệu lực của cận vận tốc"). Cuối cùng, với h nhất quán, hàng đợi theo khoá (4.16) tương đương TD-Dijkstra trên trọng số rút gọn không âm, nên Định lý 4.1 áp dụng được. □

Bổ đề 4.1 *Thủ tục (4.9) chỉ làm tăng vận tốc, dừng sau hữu hạn bước, và kết quả thoả $-d\tau_e/dt \le \kappa < 1$ trên mọi đoạn, do đó thoả FIFO.*

Chứng minh. Với v_u cố định, vế phải của (4.8) giảm ngặt khi v_ℓ tăng, nên giá trị x trong (4.9) là vận tốc nhỏ nhất làm độ dốc bằng κ; thay v_ℓ bằng $\max(v_\ell, x)$ chỉ làm vận tốc tăng. Mỗi lần sửa có thể làm đoạn kề phía trước vi phạm, nhưng dãy vận tốc ở mỗi ô là không giảm và bị chặn trên bởi vận tốc lớn nhất của các ô kề, nên thủ tục hội tụ. Khi không còn vi phạm, $-\tau' \le \kappa < 1$, tức (2.7) thoả. □

Mệnh đề 4.2 *Hàm $\tilde{a}$ trong (4.11) không giảm, $\tilde{a} \le a$, và $\tilde{a}(t) = a(t)$ tại mọi t mà a đã không giảm trên $[t, \infty)$.*

Chứng minh. Với $t_1 \le t_2$, tập $\{t' \ge t_2\} \subseteq \{t' \ge t_1\}$ nên $\tilde{a}(t_1) \le \tilde{a}(t_2)$. Chọn $t' = t$ cho $\tilde{a}(t) \le a(t)$. Nếu a không giảm trên $[t, \infty)$ thì cực tiểu đạt tại $t' = t$. Nội suy tuyến tính giữa các điểm lưới của một dãy không giảm vẫn là hàm không giảm. □

Mệnh đề 4.3 *Định hình* (4.32) *có dạng thế năng. Với tổng thưởng không chiết khấu* ($\gamma = 1$) *nó không làm thay đổi tập chính sách tối ưu* [27] *và tổng định hình trên mọi quỹ đạo từ* s *tới đích bằng* $\lambda\, ctg_{tự\ do}(s)$*, không phụ thuộc đường đi. Với* $\gamma = 0{,}995$ *như cấu hình PPO, bất biến này chỉ* xấp xỉ*; dạng bảo toàn chính xác là* $F(u, u') = \gamma\Phi(u') - \Phi(u)$.

Chứng minh. Tổng $\sum_k \big(\Phi(u_{k+1}) - \Phi(u_k)\big)$ là tổng lồng nhau, bằng $\Phi(d) - \Phi(s) = \mathrm{ctg}(s)$ vì $\mathrm{ctg}(d) = 0$. Hằng số này chỉ phụ thuộc trạng thái đầu nên không làm thay đổi thứ tự giữa các chính sách. Với chiết khấu $\gamma < 1$ và F không nhân γ, tổng định hình chiết khấu của quỹ đạo $u_0, \dots, u_T = d$ bằng $\mathrm{ctg}(u_0) - (1 - \gamma)\sum_{j=1}^{T-1} \gamma^{j-1}\mathrm{ctg}(u_j)$; số hạng sau phụ thuộc đường đi, khác 0 nhưng nhỏ vì $1 - \gamma = 0{,}005$, và nghiêng về các quỹ đạo đi qua nút gần đích hơn. Vì vậy cài đặt hiện tại không bảo đảm chính xác việc giữ nguyên chính sách tối ưu; cách sửa là dùng $F = \gamma\Phi(u') - \Phi(u)$ và huấn luyện lại. Kiểm thử đơn vị chỉ kiểm chứng đẳng thức không chiết khấu. □

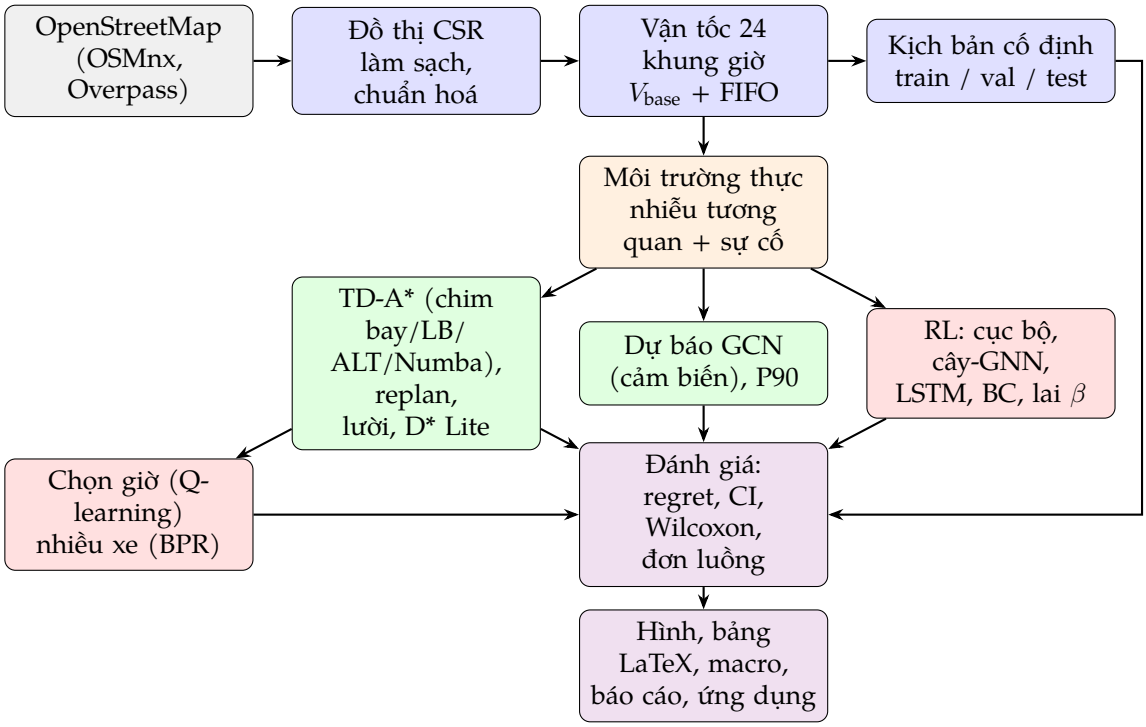
Độ phức tạp. Với hàng đợi nhị phân và việc tính $\tau_e(t)$ mất $O(1)$, độ phức tạp của các thành phần chính được tổng hợp trong Bảng 4.3 (ở đây $m/n \approx 2{,}57$; L là số điểm mốc; S là số giao lộ trên tuyến; ℓ, H là số lớp và kích thước lớp ẩn của GCN; M, k là số kịch bản và số ứng viên; N là số xe; I là số vòng lặp điểm bất động).

Bảng 4.3: Độ phức tạp thời gian và bộ nhớ của các thành phần.

Thành phần	**Thời gian**	**Bộ nhớ**
TD-Dijkstra / TD-A*	$O((n+m)\log n)$ mỗi truy vấn	$O(n+m)$
Heuristic LB	$+\,O((n+m)\log n)$ mỗi đích	$O(n)$
Heuristic ALT	tiền xử lý $O(L(n+m)\log n)$; mỗi $h(v)$ là $O(L)$	$O(Ln)$
Replan / replan lười	$O(S(n+m)\log n)$ / $O(S'(n+m)\log n)$, $S' \le S$	$O(n+m)$
D* Lite	dựng lại $O((n+m)\log n)$; cập nhật tăng dần chỉ các nút đổi khoá	$O(n+m)$
Suy luận GCN	$O(\ell \cdot \mathrm{nnz}(\hat{A}) \cdot H)$	$O(mH)$
Định tuyến P90	$O(k \cdot \text{Yen} + M\,k\,\lvert P\rvert)$	$O(M\,m \cdot 24)$
Mô phỏng nhiều xe	$O(N \cdot \text{TD-A*} + I\,N\,\lvert P\rvert)$	$O(m \cdot \#\text{khung})$
Chính sách RL	$O(\lvert P\rvert)$ lượt suy luận mạng; biến thể lai thêm một TD-A* mỗi bước	số tham số mạng

4.4 Lược đồ hoặc sơ đồ minh hoạ

Hình 4.5 là sơ đồ khối luồng dữ liệu của toàn hệ thống. Thuật toán 1 và Thuật toán 2 là mã giả của hai thành phần tìm kiếm cốt lõi; Thuật toán 3 mô tả quy trình huấn luyện biến thể RL cây-GNN + BC.



Hình 4.5: Sơ đồ khối của hệ thống: luồng dữ liệu từ OpenStreetMap tới đánh giá và báo cáo.

Thuật toán 1 TD-A* (nhãn là thời điểm đến)

Vào: Đồ thị G, nguồn s, đích d, giờ t_0, hàm $\tau_e(t)$, heuristic nhất quán h
Ra: Tuyến đến sớm nhất và thời điểm đến

$\text{arr}[s] \leftarrow t_0$; $Q \leftarrow \{(t_0 + h(s), s)\}$; $C \leftarrow \emptyset$
while $Q \neq \emptyset$ **do**
  $(\cdot, u) \leftarrow \textsc{PopMin}(Q)$; **if** $u \in C$ **then continue**
  $C \leftarrow C \cup \{u\}$; **if** $u = d$ **then return** truy vết(pred, d), $\text{arr}[d]$
  for $e = (u, v) \in \text{out}(u)$ với $v \notin C$ **do**
    $t' \leftarrow \text{arr}[u] + \tau_e(\text{arr}[u])$ ▷ nới lỏng (4.15)
    if $t' < \text{arr}[v]$ **then**
      $\text{arr}[v] \leftarrow t'$; $\text{pred}[v] \leftarrow e$; $\textsc{Push}(Q, (t' + h(v), v))$
    end if
  end for
end while

Thuật toán 2 Replan (tuỳ chọn lười) với quan sát cục bộ và dự báo GCN

Vào: s, d, t_0; dự báo τ^{base}; môi trường thực τ^{real}; bán kính r; ngưỡng θ (chế độ lười)

$u \leftarrow s$; $t \leftarrow t_0$; $\Delta \leftarrow \{\}$; $P \leftarrow [\,]$
while $u \neq d$ **do**
  cần $\leftarrow (P = [\,])$ ▷ chế độ đầy đủ: luôn đặt cần $\leftarrow$ true
  for mỗi cạnh e có nút đầu cách u không quá r **do**
    $\delta \leftarrow \tau_e^{\text{real}}(t) - \tau_e^{\text{base}}(t)$ ▷ (4.21)
    if $|\delta - \Delta_{\text{lúc lập}}[e]| > \theta\, \tau_e^{\text{base}}(t)$ **then** cần $\leftarrow$ true
    end if ▷ (4.23)
    $\Delta[e] \leftarrow \delta$
  end for
  if cần **then**
    $\tau^{\text{base}} \leftarrow$ GCN(cảm biến, quan sát) nếu dùng dự báo GCN ▷ (4.27)
    $P \leftarrow$ TD-A*(u, d, t) trên τ^{obs} ▷ (4.22)
  end if
  $e \leftarrow \textsc{PopFront}(P)$; $t \leftarrow t + \tau_e^{\text{real}}(t)$; $u \leftarrow \text{head}(e)$
end while
return $t - t_0$

Thuật toán 3 Huấn luyện RL cây-GNN + BC

Vào: Tập cặp điểm huấn luyện; số tập thu thập N_{BC}; xác suất khám phá p
Ra: Chính sách π_θ (checkpoint tốt nhất theo tập kiểm định)

$\mathcal{D} \leftarrow \emptyset$
for $i = 1, \ldots, N_{\text{BC}}$ **do**
  Sinh tập mới (cặp điểm, giờ, nhiễu, sự cố); $P \leftarrow$ TD-A* trên V_{real} ▷ oracle
  while chưa kết thúc **do**
    $a^* \leftarrow$ chỉ số cạnh đầu của P; $\mathcal{D} \leftarrow \mathcal{D} \cup \{(o, a^*, \mu)\}$
    thực thi $a \leftarrow$ ngẫu nhiên hợp lệ với xác suất p, ngược lại a^*
    if $a \neq a^*$ **then** $P \leftarrow$ TD-A* lại từ trạng thái mới **else** bỏ cạnh đầu của P
  end while
end for
Cực tiểu $\mathcal{L}_{\text{BC}}$ (4.35) bằng Adam trên $\mathcal{D}$
Tinh chỉnh bằng MaskablePPO (4.33) theo chương trình 3 mức; đánh giá định kỳ trên tập kiểm định, lưu checkpoint tốt nhất

5 Kết quả thực nghiệm

5.1 Cấu hình thực nghiệm

Môi trường chạy. Toàn bộ thực nghiệm chạy trên một máy tính xách tay chỉ dùng CPU; cấu hình phần cứng và phần mềm được liệt kê ở Bảng 5.1. Mã

nguồn viết bằng Python, phần lõi tìm kiếm dùng `heapq` trên cấu trúc CSR (thư viện NetworkX chỉ dùng để đối chiếu kết quả trong kiểm thử đơn vị).

Bảng 5.1: Môi trường phần cứng và phần mềm.

Thành phần	**Cấu hình**
Phần cứng	Laptop Intel 16 luồng, chỉ CPU (không dùng GPU)
Hệ điều hành	Windows 11; kiểm tra lại trong container Docker Linux
Ngôn ngữ	Python 3.13
Dữ liệu bản đồ	OSMnx 2.1, GeoPandas, Shapely
Tính toán số	NumPy, SciPy, Numba 0.68
Học tăng cường	Gymnasium 1.4, Stable-Baselines3 / sb3-contrib 2.9, PyTorch 2.10
Trực quan, giao diện	Matplotlib, Seaborn, Streamlit, Folium, pydeck
Kiểm thử	pytest (55 kiểm thử đơn vị)

Cách chọn tham số và số lần lặp. Seed toàn cục là 42; mọi seed con (nhiễu của từng truy vấn, môi trường RL, khởi tạo mạng) được dẫn xuất tất định từ seed này. Các tham số mô phỏng (biên độ cao điểm, độ nhạy loại đường, hệ số hướng, mức nhiễu) được chọn theo hiểu biết chung về giao thông đô thị và hiệu chỉnh sơ bộ để vận tốc trung bình hợp lý; các tham số thuật toán (bán kính quan sát, ngưỡng lười, số điểm mốc, hệ số thưởng) được đặt theo giá trị hợp lý, không tinh chỉnh theo kết quả trên tập kiểm tra, và nằm cố định trong tệp cấu hình. Mỗi biến thể RL được huấn luyện với 3 seed; ngân sách số bước từ 60 nghìn (biến thể lai) tới 1 triệu (định hình ctg), xem Bảng 5.16. Chính sách được đánh giá định kỳ trên 100 truy vấn kiểm định và lưu checkpoint có điểm cao nhất theo

$$\text{score} = \text{tỉ lệ tới đích} - 0{,}002 \times \text{regret (\%)}, \tag{5.1}$$

và bảng chính dùng seed tốt nhất theo tập kiểm định (không chọn theo tập kiểm tra). Thời gian tính được đo *đơn luồng* (một tiến trình, tuần tự, sau khi làm nóng bộ nhớ đệm và JIT) trên 50 truy vấn kiểm tra. Bảng tham số đầy đủ ở Phụ lục (Bảng A.1).

5.2 Phương pháp baseline để so sánh

- **Dijkstra ngắn nhất** [1]: tuyến ngắn nhất theo chiều dài. Ưu điểm: đơn giản, rất nhanh; nhược điểm: không biết giờ cao điểm. Đây là mốc "không

dùng thông tin giao thông".

- **A* theo thời gian tự do** [2]: tuyến nhanh nhất khi đường thông thoáng; biết loại đường nhưng không biết ùn tắc theo giờ.
- **Plan-once TD-A*** [4, 11]: tối ưu theo dự báo lúc xuất phát, không thích nghi trong khi đi.
- **Oracle TD-A***: chạy TD-A* trên chính V_{real} (biết trước tương lai) — không khả thi trong thực tế, chỉ dùng làm cận dưới để tính regret (2.11).
- **Tham lam cục bộ**: chọn cạnh có cosin hướng đích lớn nhất, phạt nút đã thăm; dùng *cùng* quan sát với RL cục bộ nên là mốc dưới tự nhiên cho các chính sách RL.
- **Replan TD-A***: baseline thích nghi chính, dùng để đánh giá các phương pháp mới (replan lười, D* Lite, GCN, RL lai).

5.3 Các bộ dữ liệu sử dụng

Dữ liệu thực (real-world). Mạng đường OpenStreetMap của quận Hà Đông cộng vùng đệm 500 m: 3482 nút, 8944 cạnh, 944,5 km (Bảng 4.1); toạ độ các điểm nóng lấy từ Nominatim.

Dữ liệu tổng hợp (synthetic). Vận tốc 24 khung giờ được mô phỏng theo Mục 4.2.2; môi trường thực theo Mục 4.2.3. Tập truy vấn gồm 1000 truy vấn được sinh với các ràng buộc: khoảng cách chim bay giữa hai điểm ít nhất 1 km, giờ xuất phát lấy mẫu có trọng số ưu tiên cao điểm, mức nhiễu $\sigma \in \{0{,}05; 0{,}15; 0{,}30\}$, số sự cố $\{0, 1, 2, 3\}$ với xác suất $0{,}35/0{,}30/0{,}20/0{,}15$. Tập được chia 600/200/200 (huấn luyện/kiểm định/kiểm tra) *theo cặp điểm đi–đến*, không có cặp nào xuất hiện ở hai tập; các cạnh có sự cố trong tập kiểm tra không trùng với cạnh có sự cố trong các truy vấn của tập huấn luyện. Tập kiểm tra có khoảng cách chim bay trung bình 4,58 km và trung bình 1,02 sự cố mỗi truy vấn.

Hai bộ sự cố trên cùng truy vấn. Mỗi truy vấn kiểm tra có hai bộ sự cố cùng số lượng, cùng thời điểm và cùng mức độ, chỉ khác vị trí: *tập chính* đặt sự cố ngẫu nhiên trên hành lang 600 m quanh đoạn thẳng nối hai điểm, không thiên vị phương pháp nào; *tập stress* đặt sự cố lên tuyến dự kiến của plan-once với xác suất 0,7, cố ý gây bất lợi cho plan-once để kiểm tra sức chịu đựng. GCN

được huấn luyện trên các "ngày" mô phỏng có seed riêng, độc lập với mọi tập truy vấn.

5.4 Các tiêu chí đánh giá

- **Thời gian di chuyển thực tế** (trung bình, trung vị, phân vị 90%): mục tiêu trực tiếp của người lái; phân vị 90% phản ánh độ tin cậy.
- **Regret so với oracle** (2.11): chuẩn hoá theo độ khó của từng truy vấn, cho phép so sánh giữa chuyến ngắn và chuyến dài.
- **Tỉ lệ tới đích**: chính sách RL chọn từng cạnh có thể không tới đích trong giới hạn số bước; thời gian và regret chỉ tính trên các chuyến tới đích nên luôn phải đọc kèm tỉ lệ này.
- **Số nút mở rộng và thời gian tính đơn luồng**: chi phí tính toán, lần lượt độc lập phần cứng và thực tế.
- **Ý nghĩa thống kê.** Vì mọi phương pháp chạy trên cùng truy vấn, chúng tôi so sánh *ghép cặp*. Với hiệu $D_i = T_i^A - T_i^B$ trên n truy vấn, khoảng tin cậy bootstrap [33] 95% của $\bar{D}$ là

$$\mathrm{CI}_{95\%} = \left[\widehat{q}_{0.025}\left(\bar{D}^{*(b)}\right),\ \widehat{q}_{0.975}\left(\bar{D}^{*(b)}\right)\right]_{b=1}^{B}, \tag{5.2}$$

  với $\bar{D}^{*(b)}$ là trung bình của mẫu lấy lại có hoàn lại thứ b và $B = 5000$. Kiểm định Wilcoxon signed-rank [34] dùng thống kê

$$W = \sum_{i:\, D_i \neq 0} \mathrm{sgn}(D_i)\, R_i, \tag{5.3}$$

  trong đó R_i là hạng của $|D_i|$; kiểm định không giả định phân phối chuẩn, phù hợp với phân phối lệch của regret. Cần đọc cùng khoảng tin cậy: khoảng tin cậy nói về hiệu trung bình, Wilcoxon nói về xu hướng theo hạng, nên hai kết quả có thể không cùng chiều khi phân phối hiệu lệch hoặc có nhiều giá trị bằng 0.
- **Riêng cho từng thí nghiệm.** Dự báo GCN dùng sai số căn quân phương trên các cạnh chưa quan sát:

$$\mathrm{RMSE} = \sqrt{\frac{1}{|U|}\sum_{e \in U}\left(\hat{r}_e - r_e\right)^2}, \tag{5.4}$$

với U là tập cạnh không có quan sát. Định tuyến P90 dùng trung bình và phân vị 90% trên 100 kịch bản độc lập; chọn giờ xuất phát dùng chi phí (2.13); mô phỏng nhiều xe dùng thời gian đi trung bình khi có tải (2.14).

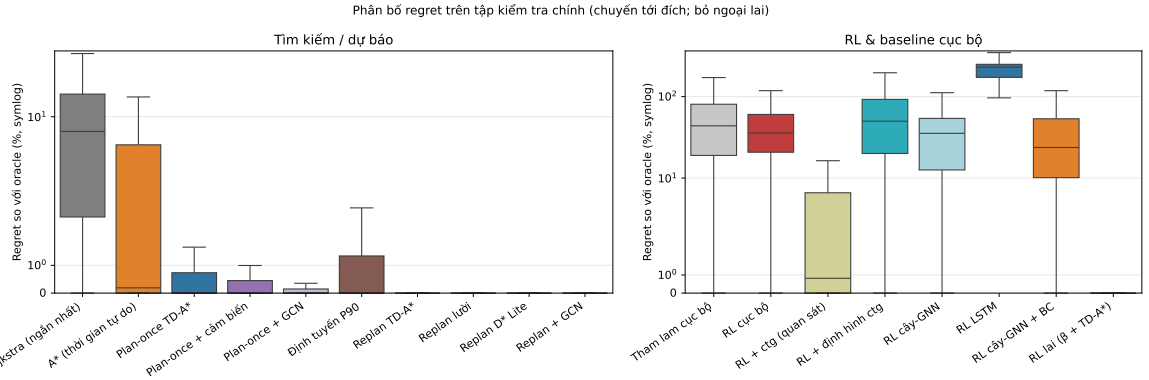
5.5 Phân tích kết quả

5.5.1 Kết quả tổng hợp: tìm kiếm, tái lập kế hoạch, dự báo

Bảng 5.2 và Hình 5.1 trình bày kết quả trên tập kiểm tra chính (200 truy vấn). Kết quả xác nhận giả thuyết H1: chỉ riêng việc tính đến sự phụ thuộc thời gian đã giảm regret trung bình từ 11,03% (Dijkstra ngắn nhất) và 5,21% (A* theo thời gian tự do) xuống 1,29% (plan-once TD-A*). Tái lập kế hoạch tiếp tục đưa regret về 0,47%; replan lười đạt 0,48% và D* Lite đạt 0,44%. Phương pháp tốt nhất là replan kết hợp dự báo GCN với regret 0,19%. Ở chế độ lập kế hoạch một lần, sử dụng cảm biến mà không lan truyền cho 0,92%, còn khi lan truyền bằng GCN cho 0,59%. Định tuyến P90 cho 1,47%. Mọi phương pháp tìm kiếm đều tới đích 100%.

Bảng 5.2: Kết quả các phương pháp tìm kiếm và dự báo trên tập kiểm tra chính (200 truy vấn, sự cố đặt ngẫu nhiên) trong môi trường thực; regret tính so với oracle.

Phương pháp	Tới đích (%)	TB (phút)	Trung vị	P90	Regret TB (%)	Regret TV (%)	Regret P90 (%)	Dài (km)
Dijkstra (ngắn nhất)	100,00	19,01	16,05	33,12	11,03	7,63	26,73	6,26
A* (thời gian tự do)	100,00	18,33	14,96	31,42	5,21	0,19	16,49	6,64
Plan-once TD-A*	100,00	17,51	14,51	31,05	1,29	0,00	4,64	6,62
Plan-once + cảm biến	100,00	17,43	14,51	30,89	0,92	0,00	2,85	6,60
Plan-once + GCN	100,00	17,39	14,47	31,04	0,59	0,00	1,22	6,58
Định tuyến P90	100,00	17,53	14,62	31,08	1,47	0,00	4,75	6,63
Replan TD-A*	100,00	17,35	14,47	30,89	0,47	0,00	1,18	6,63
Replan lười	100,00	17,36	14,47	30,89	0,48	0,00	1,18	6,64
Replan D* Lite	100,00	17,37	14,47	31,04	0,44	0,00	1,44	6,62
Replan + GCN	100,00	17,31	14,47	31,04	0,19	0,00	0,01	6,61
Oracle TD-A*	100,00	17,26	14,47	30,89	0,00	0,00	0,00	6,64



Hình 5.1: Phân bố regret theo phương pháp trên tập kiểm tra chính (chuyến tới đích; trục tung dạng symlog).

Kiểm định thống kê (Bảng 5.3). Với mỗi cặp (A, B), chúng tôi báo cáo hiệu thời gian trung bình $\bar{D} = \overline{T^A - T^B}$ (giá trị âm nghĩa là A nhanh hơn), khoảng tin cậy bootstrap 95% (5.2) và giá trị p của kiểm định Wilcoxon (5.3):

- Plan-once so với Dijkstra: $\bar{D} = -1{,}50$ phút mỗi chuyến, khoảng tin cậy $[-1{,}74; -1{,}27]$, $p < 10^{-4}$.
- Replan so với plan-once: $\bar{D} = -0{,}16$ phút, khoảng tin cậy $[-0{,}25; -0{,}08]$, $p < 10^{-4}$.
- Replan + GCN so với replan: $\bar{D} = -0{,}05$ phút, khoảng tin cậy $[-0{,}11; 0{,}01]$, $p = 0{,}0186$.
- Plan-once + GCN so với plan-once: $\bar{D} = -0{,}12$ phút, khoảng tin cậy $[-0{,}20; -0{,}06]$, $p < 10^{-4}$.
- Replan lười so với replan: $\bar{D} = 0{,}00$ phút, khoảng tin cậy $[0{,}00; 0{,}00]$ — thực tế không khác biệt; D* Lite so với replan: $\bar{D} = 0{,}02$ phút, khoảng tin cậy $[-0{,}04; 0{,}08]$ chứa 0.
- Định tuyến P90 so với plan-once: $\bar{D} = 0{,}02$ phút, khoảng tin cậy $[-0{,}01; 0{,}04]$, $p = 0{,}0027$. Hai kết quả này đo hai đại lượng khác nhau: khoảng tin cậy áp dụng cho hiệu *trung bình*, còn Wilcoxon (bỏ các cặp có $D_i = 0$, vốn chiếm đa số vì hai tuyến thường trùng nhau) kiểm tra xu hướng lệch theo *hạng* của hiệu. Ở các truy vấn hai phương pháp đi khác nhau, P90 thường chậm hơn nhẹ (nên Wilcoxon có ý nghĩa), nhưng một số ít truy vấn nhanh hơn nhiều kéo trung bình về gần 0 (nên khoảng tin cậy chứa

0). Kết luận thận trọng: P90 không cho lợi ích nhất quán, và nếu có chênh lệch thì rất nhỏ so với phương sai giữa các truy vấn.

Các khác biệt tính bằng phút là nhỏ vì phần lớn truy vấn không chịu ảnh hưởng của sự cố. Khoảng tin cậy không chứa 0 ở ba cặp chính (plan-once so với Dijkstra, replan so với plan-once, oracle so với replan) và ở plan-once + GCN so với plan-once; các cặp còn lại (replan lười, D* Lite, replan + GCN, P90) có khoảng tin cậy chứa 0 hoặc chênh lệch rất nhỏ, nên chỉ nên đọc là "không phân biệt được" hoặc "cải thiện nhẹ".

Bảng 5.3: So sánh ghép cặp trên các truy vấn cả hai phương pháp cùng tới đích: khoảng tin cậy bootstrap 95% của hiệu trung bình thời gian và kiểm định Wilcoxon signed-rank.

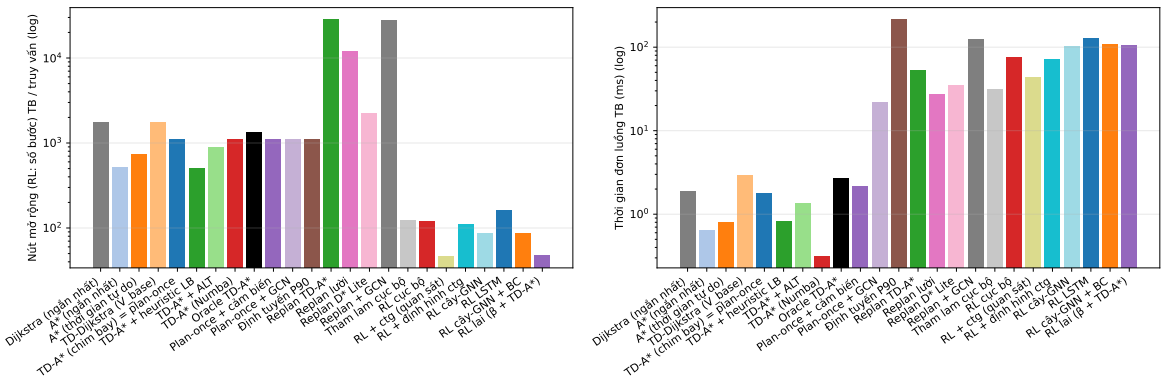
Cặp (A − B)	n	Hiệu TB (phút)	CI 95% thấp	CI 95% cao	Hiệu TB (%)	A tốt hơn (%)	p (Wilcoxon)
Plan-once TD-A* − Dijkstra (ngắn nhất)	200	-1,499	-1,738	-1,270	-7,974	78,000	$< 10^{-4}$
Replan TD-A* − Plan-once TD-A*	200	-0,159	-0,250	-0,084	-0,726	36,500	$< 10^{-4}$
Oracle TD-A* − Replan TD-A*	200	-0,090	-0,142	-0,050	-0,440	18,500	$< 10^{-4}$
Replan lười − Replan TD-A*	200	0,002	0,000	0,004	0,007	0,500	0,0687
Replan D* Lite − Replan TD-A*	200	0,015	-0,036	0,077	-0,020	3,500	0,3037
Replan + GCN − Replan TD-A*	200	-0,048	-0,105	0,005	-0,250	10,500	0,0186
Plan-once + cảm biến − Plan-once TD-A*	200	-0,081	-0,155	-0,013	-0,316	16,000	0,0297
Plan-once + GCN − Plan-once TD-A*	200	-0,124	-0,199	-0,055	-0,635	26,000	$< 10^{-4}$
Plan-once + GCN − Plan-once + cảm biến	200	-0,043	-0,093	0,008	-0,308	21,500	0,0002
Định tuyến P90 − Plan-once TD-A*	200	0,015	-0,010	0,038	0,188	6,000	0,0027
RL lai (β + TD-A*) − Replan TD-A*	200	0,013	0,004	0,025	0,082	0,000	0,0009
RL cây-GNN + BC − Plan-once TD-A*	154	5,527	4,473	6,798	35,788	3,896	$< 10^{-4}$
RL + ctg (quan sát) − A* (thời gian tự do)	200	-0,001	-0,079	0,063	0,096	7,000	0,0002

5.5.2 Chi phí tính toán

Bảng 5.4 và Hình 5.2 so sánh chi phí tính toán đơn luồng. A* giảm 70,2% số nút mở rộng so với Dijkstra. Với tìm kiếm phụ thuộc thời gian, heuristic chim bay chỉ giảm 36,5% so với TD-Dijkstra vì phải chia cho $v_{\max}$ lớn (vận tốc tự do lớn nhất) trong khi vận tốc thực tế, nhất là giờ cao điểm, thấp hơn nhiều. Heuristic cận dưới chính xác giảm 71,3% (ít hơn heuristic chim bay 54,8%) nhưng tốn 3,24 ms tiền xử lý mỗi đích; ALT giảm 49,0% với 1,55 ms để tính heuristic mỗi truy vấn (tiền xử lý điểm mốc chỉ làm một lần). TD-A* biên dịch Numba nhanh gấp 5,6 lần bản Python với cùng số nút mở rộng. Replan tốn 53,16 ms mỗi chuyến (48,6 lần tìm kiếm); replan lười nhanh gấp 2,0 lần (22,7 lần tìm kiếm); D* Lite nhanh gấp 1,5 lần (2318 nút mở rộng so với 35237 của replan). Suy luận chính sách RL (PyTorch, từng bước) tốn 43,51–127,95 ms mỗi chuyến tuỳ biến thể, chậm hơn TD-A* nhiều lần trên đồ thị cỡ này.

Bảng 5.4: Chi phí tính toán đơn luồng (một tiến trình, tuần tự, 50 truy vấn kiểm tra, sau khi làm nóng). Với RL, cột nút mở rộng là số bước chính sách.

Phương pháp	Nút mở rộng / bước TB	Thời gian TB (ms)	P90 (ms)	Tiền xử lý / truy vấn (ms)
Dijkstra (ngắn nhất)	1759	1,91	2,91	–
A* (ngắn nhất)	524	0,65	1,39	–
A* (thời gian tự do)	742	0,80	1,46	–
TD-Dijkstra (V_base)	1734	2,94	4,57	–
TD-A* (chim bay) = plan-once	1101	1,77	3,03	–
TD-A* + heuristic LB	498	0,83	1,88	3,24
TD-A* + ALT	884	1,36	2,83	1,55
TD-A* (Numba)	1101	0,32	0,50	0,00
Oracle TD-A*	1334	2,73	4,71	–
Plan-once + cảm biến	1097	2,19	3,67	–
Plan-once + GCN	1092	21,77	24,66	–
Định tuyến P90	1101	214,83	398,02	–
Replan TD-A*	28424	53,16	123,52	–
Replan lưới	11996	27,10	67,91	–
Replan D* Lite	2244	35,31	53,96	–
Replan + GCN	27618	124,38	240,06	–
Tham lam cục bộ	125	31,37	45,90	–
RL cục bộ	121	75,85	120,16	–
RL + ctg (quan sát)	47	43,51	53,69	–
RL + định hình ctg	109	72,52	119,55	–
RL cây-GNN	86	102,03	219,35	–
RL LSTM	163	127,95	169,26	–
RL cây-GNN + BC	86	108,22	215,29	–
RL lai (β + TD-A*)	47	104,62	202,55	–



Hình 5.2: Số nút mở rộng (trái) và thời gian tính đơn luồng (phải) trung bình mỗi truy vấn, thang logarit.

5.5.3 Vai trò của sự cố và tập stress

Theo số sự cố trên tập chính (Bảng 5.5): khi không có sự cố, regret của plan-once chỉ 0,83% và của replan 0,35%; với 3 sự cố, các con số tương ứng là 3,10% và 1,00%. Trên tập stress (Bảng 5.6), khi sự cố được đặt ưu tiên trên tuyến dự kiến, regret của plan-once tăng lên 3,37% trong khi replan giữ 0,67% và replan + GCN 0,31%; Dijkstra ngắn nhất 11,38%. Kết quả xác nhận giả thuyết H2: tái

lập kế hoạch có giá trị chủ yếu khi dự báo sai *cục bộ và lớn*. Bảng 5.7 cho thấy trên tập con không có sự cố, plan-once đã rất gần oracle, nên lợi ích của TD-A* so với Dijkstra là thật chứ không do cách đặt sự cố.

Bảng 5.5: Regret trung bình (%) so với oracle theo số sự cố (chuyến tới đích).

Nhóm	n	Dijkstra (ngắn nhất)	Plan-once TD-A*	Plan-once + GCN	Replan TD-A*	Replan + GCN	RL lai (β + TD-A*)	RL cây-GNN + BC
0	81	10,48	0,83	0,37	0,35	0,17	0,44	38,50
1	57	10,30	1,25	0,44	0,39	0,27	0,55	35,67
2	38	12,04	1,16	1,10	0,53	0,25	0,53	35,52
3	24	13,05	3,10	0,84	1,00	0,02	1,02	41,69

Bảng 5.6: Kết quả trên tập stress (sự cố được ưu tiên đặt trên tuyến dự kiến với xác suất 0.7): cùng 200 truy vấn, cùng thời điểm/mức độ sự cố.

Phương pháp	Tới đích (%)	TB (phút)	Trung vị	P90	Regret TB (%)	Regret TV (%)	Regret P90 (%)	Dài (km)
Dijkstra (ngắn nhất)	100,00	19,38	16,45	33,60	11,38	8,39	26,36	6,26
A* (thời gian tự do)	100,00	18,80	15,79	33,10	6,38	1,50	19,05	6,64
Plan-once TD-A*	100,00	18,10	15,47	31,84	3,37	0,23	11,44	6,62
Plan-once + GCN	100,00	17,88	15,46	31,84	2,10	0,00	5,99	6,58
Định tuyến P90	100,00	18,11	15,56	31,85	3,51	0,52	11,73	6,63
Replan TD-A*	100,00	17,71	15,28	31,84	0,67	0,00	1,93	6,67
Replan lười	100,00	17,71	15,28	31,84	0,67	0,00	1,93	6,67
Replan D* Lite	100,00	17,72	15,28	31,84	0,66	0,00	2,20	6,65
Replan + GCN	100,00	17,64	15,14	31,84	0,31	0,00	0,28	6,64
RL lai (β + TD-A*)	100,00	17,73	15,28	31,84	0,80	0,00	2,33	6,66
RL cây-GNN + BC	77,50	21,91	18,53	38,82	40,77	26,96	75,24	7,64
Oracle TD-A*	100,00	17,57	15,02	31,71	0,00	0,00	0,00	6,66

Bảng 5.7: Kết quả trên tập con kiểm tra không có sự cố (81 truy vấn).

Phương pháp	Tới đích (%)	TB (phút)	Trung vị	P90	Regret TB (%)	Regret TV (%)	Regret P90 (%)	Dài (km)
Dijkstra (ngắn nhất)	100,00	20,24	15,96	40,92	10,48	7,45	26,73	6,20
A* (thời gian tự do)	100,00	19,61	14,92	44,10	4,17	0,32	13,68	6,57
Plan-once TD-A*	100,00	18,66	14,77	38,74	0,83	0,00	2,62	6,57
Plan-once + GCN	100,00	18,57	14,39	37,68	0,37	0,00	0,97	6,49
Replan TD-A*	100,00	18,56	14,43	38,49	0,35	0,00	1,58	6,58
Replan + GCN	100,00	18,51	14,39	37,62	0,17	0,00	0,00	6,55
RL lai (β + TD-A*)	100,00	18,57	14,43	38,49	0,44	0,00	1,66	6,58
Oracle TD-A*	100,00	18,47	14,39	37,62	0,00	0,00	0,00	6,59

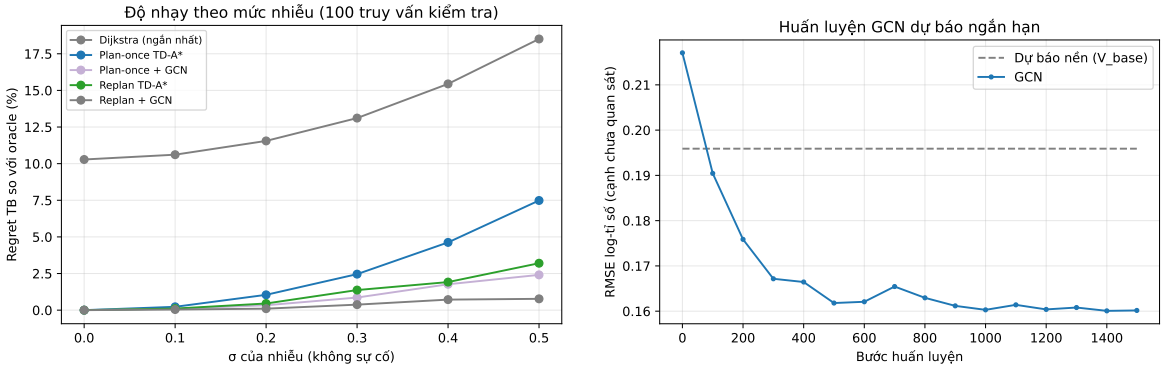
5.5.4 Mức nhiễu, dự báo GCN và định tuyến P90

GCN giảm RMSE (5.4) của log-tỉ số vận tốc trên các cạnh chưa quan sát từ 0,196 (dự báo nền) xuống 0,160, tức giảm 18,2% (Bảng 5.8, Hình 5.3). Lợi ích này chuyển thành chất lượng tuyến và tăng theo mức nhiễu (Hình 5.3, Bảng 5.9): với $\sigma = 0{,}5$ và không có sự cố, regret của plan-once là 7,49%, plan-once + GCN 2,41%, replan 3,20%, replan + GCN 0,77% và Dijkstra 18,51%. Điều này chỉ xảy ra vì nhiễu có tương quan không gian–thời gian; với nhiễu

độc lập (phiên bản đầu của dự án) quan sát không mang thông tin về các cạnh khác nên không có gì để lan truyền.

Bảng 5.8: Sai số dự báo log-tỉ số vận tốc (mốc h và $h+1$) trên 20 trường kiểm định độc lập; 1341 cảm biến (15% cạnh) + cạnh trong bán kính quan sát.

Mô hình	RMSE cạnh chưa quan sát	RMSE mọi cạnh
Dự báo nền V_base (log-tỉ số = 0)	0,1959	0,1965
GCN chưa huấn luyện	0,2375	0,2381
GCN đã huấn luyện	0,1602	0,1526



Hình 5.3: Trái: regret theo mức nhiễu σ khi không có sự cố. Phải: RMSE trên cạnh chưa quan sát trong quá trình huấn luyện GCN.

Bảng 5.9: Regret trung bình (%) theo mức nhiễu σ khi không có sự cố.

σ	Dijkstra (ngắn nhất)	Plan-once TD-A*	Plan-once + GCN	Replan TD-A*	Replan + GCN
0,00	10,28	0,00	0,00	0,00	0,00
0,10	10,61	0,23	0,09	0,11	0,04
0,20	11,55	1,05	0,33	0,45	0,10
0,30	13,11	2,46	0,86	1,37	0,38
0,40	15,44	4,62	1,77	1,92	0,72
0,50	18,51	7,49	2,41	3,20	0,77

Định tuyến P90 không mang lại lợi ích. Trên 100 truy vấn, mỗi tuyến được đánh giá trên 100 kịch bản độc lập (Bảng 5.10). Tuyến P90 khác tuyến plan-once ở 20,0% số truy vấn, nhưng ở các truy vấn đó phân vị 90% thực tế thay đổi trung bình 0,087 phút (dương nghĩa là tệ hơn) và chỉ tốt hơn ở 20,0% số truy vấn trong nhóm đã đổi tuyến đó. Có hai nguyên nhân: (i) với $M = 30$ kịch bản, phân vị ước lượng có sai số đáng kể, nên việc chọn ứng viên có phân vị *ước lượng* nhỏ nhất dẫn đến hiện tượng "lời nguyền người thắng" — ứng viên

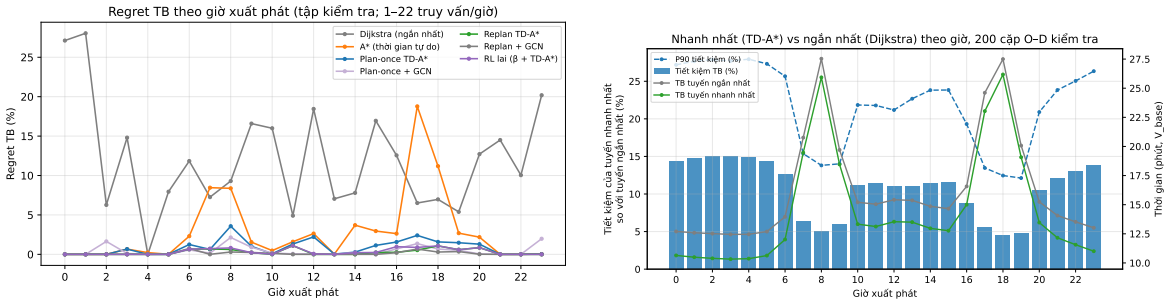
được chọn thường là ứng viên được ước lượng thấp hơn thực tế; (ii) trong mô phỏng, các tuyến ứng viên chồng lấp nhiều và nhiễu tương quan không gian khiến chúng chịu rủi ro gần như nhau, nên không tồn tại tuyến "an toàn" rõ rệt.

Bảng 5.10: Độ tin cậy tuyến trên 100 kịch bản nhiễu độc lập cho mỗi truy vấn (100 truy vấn kiểm tra, không sự cố). Tuyến P90 khác tuyến plan-once ở 20% truy vấn.

Tuyến	TB thời gian (phút)	P90 (phút)	Độ lệch chuẩn
Plan-once TD-A*	16,787	17,691	0,709
Định tuyến P90	16,798	17,708	0,710

5.5.5 Theo giờ xuất phát và khoảng cách

Regret của tuyến ngắn nhất *thấp hơn* vào giờ cao điểm (7,46%) so với thấp điểm (13,13%) (Bảng 5.11, Hình 5.4). Phân tích tuyến nhanh nhất so với tuyến ngắn nhất trên vận tốc nền (Hình 5.4, Bảng 5.14) xác nhận: tuyến nhanh nhất tiết kiệm 15,1% lúc 3h nhưng chỉ 5,1% lúc 8h và 4,4% lúc 18h. Nguyên nhân nằm ở mô hình: trục chính có độ nhạy và hệ số trục nóng cao nhất nên vào cao điểm chậm gần bằng đường nhánh (Hình 4.2); lợi thế "đi đường lớn dù xa hơn" biến mất và tuyến nhanh nhất hội tụ về tuyến ngắn. Đây là hệ quả của giả định mô phỏng và cần được kiểm chứng với dữ liệu thật; về tuyệt đối, chuyến đi vẫn dài hơn nhiều vào cao điểm (tuyến ngắn nhất 27,53 phút lúc 8h so với 12,45 phút lúc 3h). Theo khoảng cách (Bảng 5.12), regret tương đối của plan-once giảm khi chuyến đi dài hơn vì một sự cố chiếm tỉ trọng nhỏ hơn trong tổng thời gian.



Hình 5.4: Trái: regret theo giờ xuất phát. Phải: tiết kiệm của tuyến nhanh nhất so với tuyến ngắn nhất theo giờ.

Bảng 5.11: Regret trung bình (%) so với oracle theo giờ xuất phát (cao điểm: 7h, 8h, 17h, 18h) (chuyến tới đích).

Nhóm	n	Dijkstra (ngắn nhất)	Plan-once TD-A*	Plan-once + GCN	Replan TD-A*	Replan + GCN	RL lai (β + TD-A*)	RL cây-GNN + BC
cao điểm	74	7,46	1,91	0,98	0,76	0,29	0,88	28,20
thấp điểm	126	13,13	0,92	0,36	0,31	0,14	0,37	42,46

Bảng 5.12: Regret trung bình (%) so với oracle theo khoảng cách O–D (chuyến tới đích).

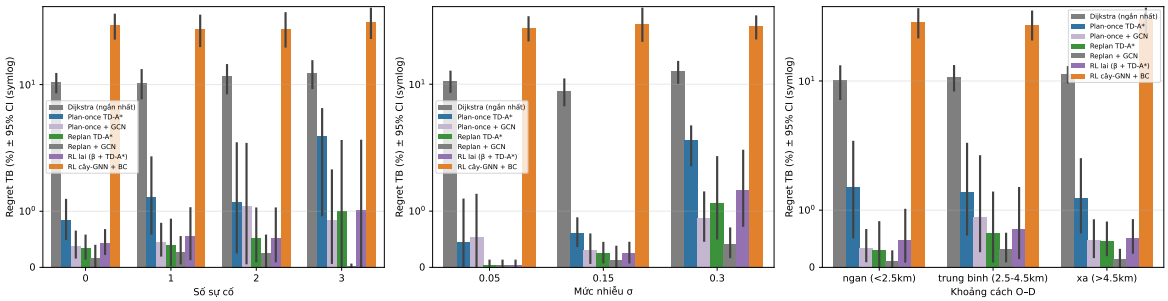
Nhóm	n	Dijkstra (ngắn nhất)	Plan-once TD-A*	Plan-once + GCN	Replan TD-A*	Replan + GCN	RL lai (β + TD-A*)	RL cây-GNN + BC
ngan (<2.5km)	42	10,18	1,39	0,34	0,31	0,11	0,48	37,09
trung binh (2.5-4.5km)	67	10,86	1,32	0,88	0,60	0,32	0,66	35,11
xa (>4.5km)	91	11,56	1,21	0,48	0,45	0,14	0,51	39,63

Bảng 5.13: Regret trung bình (%) so với oracle theo mức nhiễu σ (chuyến tới đích).

Nhóm	n	Dijkstra (ngắn nhất)	Plan-once TD-A*	Plan-once + GCN	Replan TD-A*	Replan + GCN	RL lai (β + TD-A*)	RL cây-GNN + BC
0.05	76	10,84	0,46	0,54	0,04	0,04	0,04	36,15
0.15	56	8,49	0,61	0,30	0,25	0,13	0,26	39,16
0.3	68	13,34	2,77	0,88	1,14	0,41	1,38	37,38

Bảng 5.14: Tiết kiệm thời gian của tuyến nhanh nhất so với tuyến ngắn nhất (trên vận tốc nền) theo giờ xuất phát.

Giờ	Ngắn nhất (phút)	Nhanh nhất (phút)	Tiết kiệm TB (%)	P90 (%)	Dài thêm (%)
0	12,70	10,64	14,38	27,19	6,1
3	12,45	10,33	15,06	27,72	6,1
6	13,96	12,01	12,61	25,67	5,4
7	20,76	19,47	6,30	15,37	3,7
8	27,53	25,93	5,06	13,81	3,9
9	19,70	18,46	6,01	14,02	4,2
12	15,42	13,54	10,96	21,18	4,9
14	14,86	12,97	11,44	23,82	5,0
16	16,57	15,00	8,81	19,31	4,1
17	24,61	23,03	5,61	13,47	5,9
18	27,50	26,18	4,45	12,46	6,0
19	20,07	19,07	4,81	12,12	3,3
21	14,07	12,16	12,15	23,83	5,3



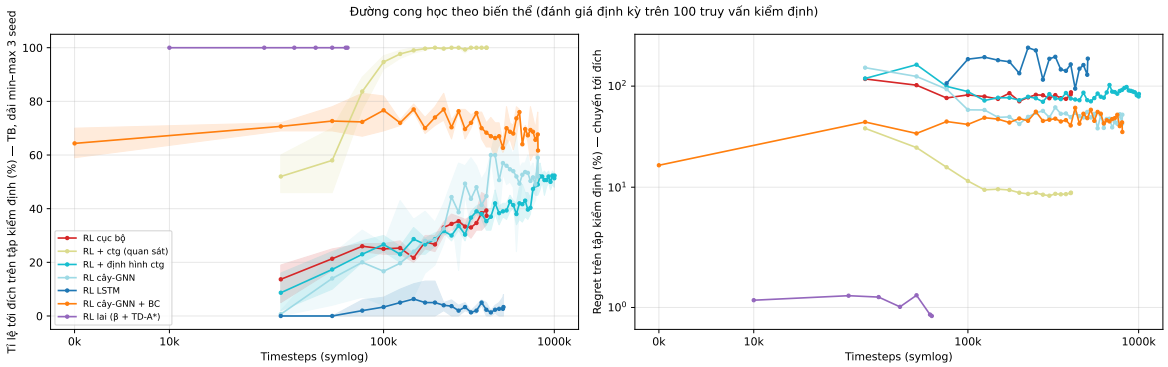
Hình 5.5: Regret theo số sự cố, mức nhiễu và khoảng cách (thanh lỗi: khoảng tin cậy bootstrap 95%; trục symlog).

5.5.6 Học tăng cường

Bảng 5.15 (seed tốt nhất theo tập kiểm định), Bảng 5.16 (mọi seed) và Hình 5.6 trình bày kết quả RL. Tỉ lệ tới đích trên tập kiểm tra, trung bình qua 3 seed: RL cục bộ 36,7%, RL + định hình ctg 55,0%, RL cây-GNN 68,0%, RL cây-GNN + BC 79,8%, RL LSTM 4,0%; baseline tham lam thủ công đạt 37,5%.

Bảng 5.15: Kết quả các biến thể học tăng cường (seed tốt nhất theo tập kiểm định) và baseline tham lam trên cùng tập kiểm tra; thời gian và regret chỉ tính trên các chuyến tới đích.

Phương pháp	Tới đích (%)	TB (phút)	Trung vị	P90	Regret TB (%)	Regret TV (%)	Regret P90 (%)	Dài (km)
Tham lam cục bộ	37,50	21,02	17,56	38,70	62,88	43,80	135,28	6,75
RL cục bộ	35,00	22,27	18,83	42,88	63,24	35,74	90,16	7,17
RL + ctg (quan sát)	100,00	18,32	15,23	31,52	5,19	0,82	17,79	6,64
RL + định hình ctg	57,00	24,18	20,50	43,68	76,11	49,93	183,88	7,87
RL cây-GNN	67,00	20,55	18,60	35,43	39,38	35,44	87,93	7,31
RL LSTM	2,50	22,83	23,23	29,17	219,06	230,42	307,75	6,36
RL cây-GNN + BC	77,00	21,59	17,74	40,35	37,36	23,74	73,33	7,57
RL lai (β + TD-A*)	100,00	17,37	14,47	30,89	0,56	0,00	1,67	6,63
Replan TD-A*	100,00	17,35	14,47	30,89	0,47	0,00	1,18	6,63
Oracle TD-A*	100,00	17,26	14,47	30,89	0,00	0,00	0,00	6,64



Hình 5.6: Đường cong học trên tập kiểm định: trung bình và dải min–max qua 3 seed (trục hoành symlog).

Cải tiến nào có tác dụng?

- *Quan sát rộng hơn có tác dụng lớn nhất trong nhóm chọn từng cạnh.* Cây lân cận 3 bước với GNN nâng tỉ lệ tới đích từ 35,0% lên 67,0% và giảm regret từ 63,24% xuống 39,38%: tác tử nhìn thấy ngõ cụt phía trước (12,9% số nút là ngõ cụt) thay vì chỉ thấy hướng chim bay. Đường cong học tăng nhanh ở nửa đầu rồi dao động mạnh quanh một mức gần như không đổi ở nửa sau ngân sách (Hình 5.6); chưa đủ bằng chứng để nói huấn luyện lâu hơn sẽ cải thiện thêm.

- *Học bắt chước cho kết quả tốt nhất.* Chỉ riêng giai đoạn BC đã đạt độ chính xác bắt chước 92,5% và 64,3% tới đích trên tập kiểm định (trung bình 3 seed) trước khi chạy PPO; seed được chọn đạt 77,0% trên tập kiểm tra (regret 37,36%). Tuy nhiên PPO tinh chỉnh *không* cải thiện thêm mà làm chính sách dao động và, ở một số seed, giảm dần (Hình 5.6); checkpoint tốt nhất thường xuất hiện sớm. Đây là hiện tượng thường gặp khi tinh chỉnh bằng gradient chính sách với phần thưởng thưa sau giai đoạn bắt chước.

- *Định hình theo cost-to-go* tăng tỉ lệ tới đích (57,0% so với 35,0%) nhưng regret trên các chuyến tới đích không giảm (76,11%): định hình chỉ hướng tác tử về đích mà không dạy nó tránh đoạn chậm.

- *Bộ nhớ LSTM thất bại* (2,5%): RecurrentPPO không có mặt nạ hành động nên phải ánh xạ a mod $\deg^+(u)$, làm ý nghĩa của mỗi đầu ra thay đổi theo bậc của nút; cộng với tốc độ học chậm hơn nhiều, chính sách không thoát khỏi việc đi lòng vòng.

- *Thí nghiệm đối chứng có thông tin toàn cục* (cost-to-go trong quan sát) tới đích 100,0% với regret 5,19%, nhưng tuyến của nó trùng hệt tuyến A* thời gian tự do ở 64,0% số truy vấn và thời gian không khác biệt đáng kể so với A* tự do về trung bình (hiệu -0,00 phút, khoảng tin cậy $[-0{,}08;\ 0{,}06]$; Bảng 5.3): chính sách chủ yếu bám theo gradient của cost-to-go tĩnh.

- *RL lai đạt 100% tới đích với regret 0,56%* nhưng không vượt được replan thuần (0,47%): hiệu 0,01 phút mỗi chuyến, khoảng tin cậy $[0{,}00;\ 0{,}03]$, Wilcoxon $p = 0{,}0009$. Tác tử học được $\bar{\beta} = 0{,}87$, gần với $\beta = 1$ của replan, và tuyến trùng replan ở 93,5% số truy vấn. Giá trị của RL ở đây là *giữ*

được bảo đảm tới đích và chất lượng của tìm kiếm, chứ chưa tạo thêm lợi ích.

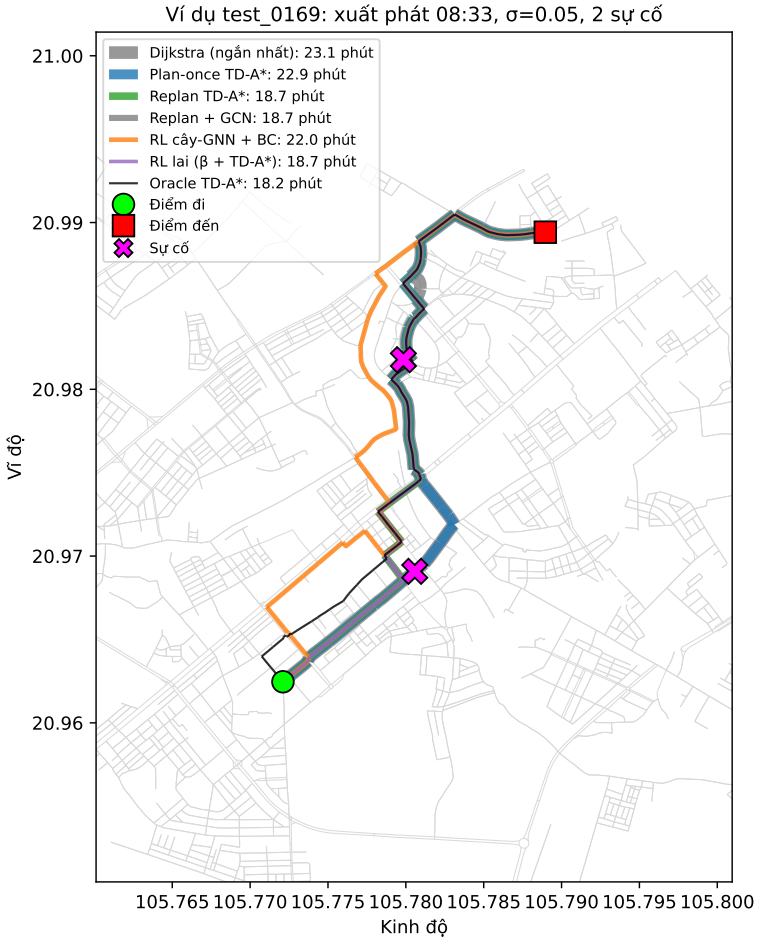
Mọi biến thể RL chọn từng cạnh *không dùng thông tin toàn cục* vẫn kém plan-once rất xa: biến thể tốt nhất trong nhóm này (cây-GNN + BC) chậm hơn plan-once 5,53 phút mỗi chuyến trên các truy vấn nó tới đích ($[4{,}47; 6{,}80]$) và chỉ tốt hơn ở 3,9% số truy vấn. Kết quả xác nhận giả thuyết H3.

Bảng 5.16: Kết quả học tăng cường theo từng seed (checkpoint tốt nhất theo tập kiểm định; cột Chọn đánh dấu seed dùng cho bảng chính).

Biến thể	Seed	Bước	Val tới đích (%)	Tốt nhất tại	Test tới đích (%)	Test regret (%)	Huấn luyện (phút)	Chọn
RL cục bộ	0	401408	46,0	375000	35,0	63,24	21,5	x
RL cục bộ	1	401408	39,0	400000	37,0	62,18	19,4	
RL cục bộ	2	401408	37,0	375000	38,0	66,14	19,8	
RL + ctg (quan sát)	0	401408	100,0	275000	99,0	5,34	21,1	
RL + ctg (quan sát)	1	401408	100,0	400000	100,0	5,19	21,1	x
RL + ctg (quan sát)	2	401408	100,0	300000	99,5	5,16	14,9	
RL + định hình ctg	0	1003520	57,0	825000	57,0	76,11	50,7	x
RL + định hình ctg	1	1003520	52,0	925000	49,5	63,25	50,6	
RL + định hình ctg	2	1003520	53,0	1000000	58,5	72,94	51,4	
RL cây-GNN	0	802816	68,0	600000	67,0	39,38	153,9	x
RL cây-GNN	1	802816	65,0	475000	74,0	54,33	153,5	
RL cây-GNN	2	802816	60,0	800000	63,0	42,31	155,5	
RL LSTM	0	503808	1,0	450000	2,5	219,06	169,7	x
RL LSTM	1	503808	13,0	175000	8,5	175,38	138,6	
RL LSTM	2	503808	2,0	425000	1,0	280,42	138,5	
RL cây-GNN + BC	0	802816	82,0	100000	77,0	37,36	160,7	x
RL cây-GNN + BC	1	802816	83,0	225000	86,0	42,94	160,9	
RL cây-GNN + BC	2	802816	77,0	625000	76,5	45,54	161,2	
RL lai (β + TD-A*)	0	61440	100,0	30000	100,0	0,56	11,5	x
RL lai (β + TD-A*)	1	61440	100,0	61440	100,0	0,90	11,4	
RL lai (β + TD-A*)	2	61440	100,0	60000	100,0	0,50	11,2	

Bảng 5.17: Độ trùng tuyến giữa các cặp phương pháp trên tập kiểm tra chính.

Cặp phương pháp	n	Tuyến giống hệt (%)	Jaccard cạnh TB (%)
RL + ctg (quan sát) vs A* (thời gian tự do)	200	64,0	91,7
RL cây-GNN + BC vs Oracle TD-A*	200	3,5	32,1
RL cây-GNN + BC vs Plan-once TD-A*	200	2,5	31,6
RL lai (β + TD-A*) vs Replan TD-A*	200	93,5	98,1
Plan-once TD-A* vs Oracle TD-A*	200	57,5	84,1
Replan TD-A* vs Oracle TD-A*	200	81,5	91,0
Replan lười vs Replan TD-A*	200	96,0	99,1
Replan D* Lite vs Replan TD-A*	200	88,0	94,9
Replan + GCN vs Replan TD-A*	200	86,5	92,2
Định tuyến P90 vs Plan-once TD-A*	200	77,5	94,6
A* (thời gian tự do) vs Dijkstra (ngắn nhất)	200	12,5	47,1



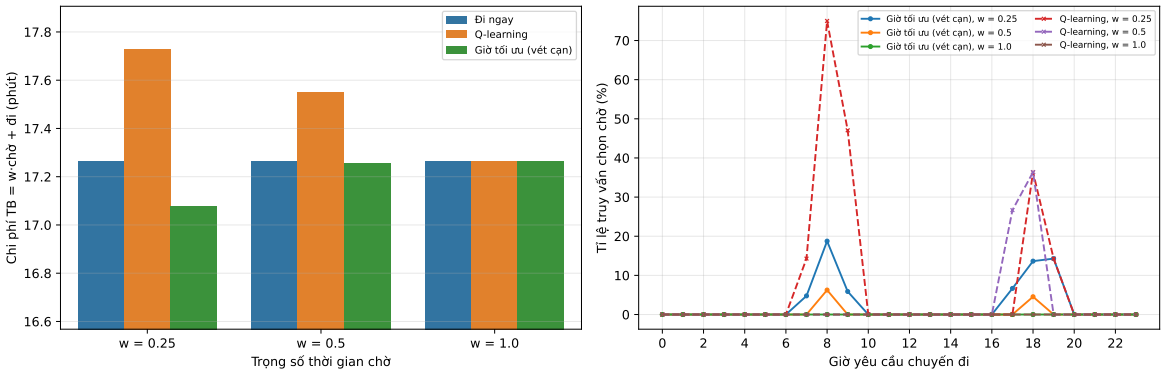
Hình 5.7: Ví dụ truy vấn test_0169 (truy vấn có sự cố với chênh lệch giữa plan-once và replan lớn nhất).

5.5.7 Chọn giờ xuất phát

Bảng 5.18 và Hình 5.8 trình bày kết quả. Khi tính đủ thời gian chờ ($w = 1$), chờ không bao giờ có lợi trên tập kiểm tra (lời giải vét cạn chọn chờ ở 0,0% số truy vấn) và Q-learning học đúng chính sách "đi ngay". Khi chờ rẻ hơn ($w = 0{,}25$), lời giải vét cạn chọn chờ ở 5,0% số truy vấn và giảm chi phí trung bình từ 17,26 xuống 17,08 phút — có truy vấn giảm được tới 24,8 phút thời gian di chuyển (chưa tính thời gian chờ) nhờ tránh cao điểm — nhưng Q-learning dạng bảng *không* nhận diện được các truy vấn đó: chi phí 17,73 phút, regret 0,649 phút so với 0,183 phút của "đi ngay". Trong lần chạy đầu, việc khởi tạo $Q = 0$ (lạc quan vì mọi phần thưởng đều âm) khiến tác tử chờ quá nhiều ở các trạng thái hiếm gặp; quy tắc chỉ tin Q ở ô đã cập nhật đủ 20 lần (Mục 4.2.9) đã khắc phục phần lớn vấn đề này.

Bảng 5.18: Kết quả thí nghiệm chọn giờ xuất phát trên tập kiểm tra (bước chờ 10 phút, tối đa 6 lần).

w	Chính sách	Chi phí TB (phút)	Đi TB (phút)	Chờ+đi TB (phút)	Tỉ lệ chờ	Regret (phút)
0,25	Đi ngay	17,26	17,26	17,26	0,000	0,183
0,25	Giờ tối ưu (vét cạn)	17,08	16,62	18,47	0,050	0,000
0,25	Q-learning	17,73	16,75	20,65	0,160	0,649
0,50	Đi ngay	17,26	17,26	17,26	0,000	0,007
0,50	Giờ tối ưu (vét cạn)	17,26	17,18	17,33	0,010	0,000
0,50	Q-learning	17,55	17,10	18,00	0,060	0,294
1,00	Đi ngay	17,26	17,26	17,26	0,000	0,000
1,00	Giờ tối ưu (vét cạn)	17,26	17,26	17,26	0,000	0,000
1,00	Q-learning	17,26	17,26	17,26	0,000	0,000



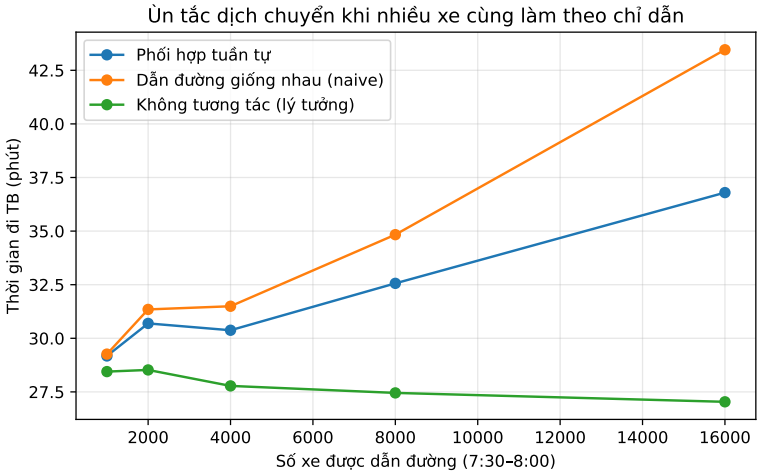
Hình 5.8: Chọn giờ xuất phát: chi phí trung bình theo chính sách (trái) và tỉ lệ chọn chờ theo giờ (phải).

5.5.8 Nhiều xe cùng được dẫn đường

Khi 16000 xe khởi hành trong khung 7:30–8:00 cùng làm theo một chỉ dẫn TD-A* trên dự báo, thời gian đi trung bình tăng từ 27,04 phút (nếu các xe không ảnh hưởng nhau) lên 43,46 phút, tức tăng 60,7% (Bảng 5.19, Hình 5.9): tải dồn vào cùng các trục "nhanh nhất" với tỉ số lưu lượng/năng lực lớn nhất tới 8,0. Phối hợp tuần tự (mỗi xe thấy tải của các xe đã lập trước) giảm thời gian còn 36,80 phút, tốt hơn 15,3% so với dẫn đường giống nhau. Kết quả xác nhận giả thuyết H4: dẫn đường cá nhân tối ưu có thể làm hệ thống tệ đi khi tỉ lệ xe dùng nó lớn, và cần phân bổ có tính đến tải (cân bằng Wardrop [14] hoặc tối ưu hệ thống).

Bảng 5.19: Thời gian đi trung bình (phút) khi nhiều xe được dẫn đường cùng lúc; V/C là tỉ số lớn nhất giữa lưu lượng dẫn đường và năng lực.

Số xe	Không tương tác	Naive	Phối hợp	V/C max (naive)	V/C max (phối hợp)
1000	28,45	29,26	29,18	0,80	0,80
2000	28,52	31,35	30,69	2,13	1,87
4000	27,78	31,49	30,38	2,67	1,87
8000	27,45	34,83	32,56	4,53	2,40
16000	27,04	43,46	36,80	8,00	3,20



Hình 5.9: Thời gian đi trung bình theo số xe được dẫn đường cùng lúc.

5.5.9 Khi nào phương pháp đề xuất tốt hơn, và tại sao

(1) **TD-A* thay cho tuyến tĩnh** luôn có lợi khi vận tốc biến thiên theo giờ: regret giảm từ 11,03% xuống 1,29%. Lợi ích tương đối nhỏ hơn vào cao điểm vì trong mô hình mọi trục đều tắc.

(2) **Replan** có lợi khi dự báo sai cục bộ và lớn (sự cố, nhiễu cao); khi dự báo tốt, plan-once đã gần tối ưu. **Replan lười** cho cùng chất lượng và nhanh gấp 2,0 lần; **D* Lite** nhanh hơn nhưng dùng chi phí snapshot nên có thể lệch nhẹ — trên đồ thị cỡ này mọi biến thể đều đủ nhanh cho ứng dụng tương tác.

(3) **Dự báo GCN** có lợi khi nhiễu có tương quan không gian–thời gian và có mạng cảm biến: replan + GCN là phương pháp tốt nhất (0,19%), và lợi ích tăng theo mức nhiễu. Với nhiễu độc lập, không có gì để lan truyền.

(4) **Định tuyến P90** không có lợi trong mô phỏng này do ước lượng phân vị từ ít mẫu và các ứng viên có rủi ro gần nhau; cần ngân hàng kịch bản lớn hơn hoặc mô hình rủi ro có cấu trúc.

(5) **RL** chỉ tiến gần được tìm kiếm khi được cung cấp thêm cấu trúc: thông tin toàn cục (cost-to-go), quan sát nhiều bước kết hợp học bắt chước, hoặc giao phần tìm đường cho TD-A* (RL lai). RL chọn từng cạnh với quan sát cục bộ không bảo đảm tới đích và còn kém một heuristic thủ công; RL lai bảo đảm tới đích nhưng chưa vượt replan. RL có thể có lợi khi không có mô hình chuyển trạng thái tường minh, khi mô hình sai lệch có hệ thống mà dữ liệu trải nghiệm phản ánh được, hoặc ở các quyết định cấp cao — những điều kiện không có trong mô phỏng hiện tại.

6 Kết luận

6.1 Tóm tắt kết quả chính

Đề tài đã xây dựng một khung thực nghiệm hoàn chỉnh cho bài toán tìm đường trong mạng giao thông động trên mạng đường OpenStreetMap của quận Hà Đông (3482 nút, 8944 cạnh, 944,5 km), với vận tốc 24 khung giờ được mô phỏng và môi trường thực có nhiễu tương quan cùng sự cố. Trên 200 truy vấn kiểm tra, các kết quả chính là:

(1) Tính đến sự phụ thuộc thời gian bằng TD-A* giảm regret từ 11,03% (tuyến ngắn nhất) xuống 1,29% (RQ1).

(2) Tái lập kế hoạch đưa regret xuống 0,47%, và replan kết hợp dự báo GCN đạt 0,19% — tốt nhất trong mọi phương pháp khả thi. Replan lười giữ nguyên chất lượng với tốc độ nhanh gấp 2,0 lần (RQ2).

(3) Heuristic cận dưới chính xác giảm 71,3% số nút mở rộng so với TD-Dijkstra (heuristic chim bay chỉ giảm 36,5%); TD-A* biên dịch Numba nhanh gấp 5,6 lần bản Python.

(4) RL chọn từng cạnh với quan sát cục bộ chỉ tới đích 35,0%; quan sát cây kết hợp GNN và học bắt chước nâng lên 77,0% nhưng vẫn kém plan-once rõ rệt. RL lai luôn tới đích với regret 0,56%, ngang nhưng không vượt replan (RQ3).

(5) Định tuyến P90 và Q-learning chọn giờ xuất phát không mang lại lợi ích trong mô phỏng; khi 16000 xe cùng làm theo một chỉ dẫn, thời gian đi tăng 60,7% và phối hợp tuần tự giảm được 15,3% (RQ4).

6.2 Đóng góp của đề tài

- Một khung thực nghiệm mã nguồn mở, tái lập được, chạy trên CPU, từ dữ liệu OpenStreetMap tới báo cáo, trong đó mọi con số được sinh tự động từ kết quả chạy.
- Một mô hình vận tốc 24 khung giờ có cấu trúc cho Hà Đông, bảo đảm tính FIFO có chứng minh (Bổ đề 4.1, Mệnh đề 4.2).
- Một bộ thuật toán tìm kiếm, tái lập kế hoạch, dự báo và định tuyến theo rủi ro được cài đặt hiệu quả và kiểm chứng bằng 55 kiểm thử đơn vị.
- Một so sánh công bằng giữa tìm kiếm có mô hình và sáu hướng cải tiến học tăng cường trên cùng môi trường, cùng tập kiểm tra, cùng chỉ số, kèm phân tích trung thực về khi nào mỗi hướng có và không có lợi.
- Ứng dụng minh hoạ trực quan và gói Docker để chạy lại trên máy khác.

6.3 Hạn chế và hướng phát triển

- **Dữ liệu tự mô phỏng.** Đây là hạn chế lớn nhất: kết luận định lượng chỉ đúng trong mô phỏng. Bước tiếp theo quan trọng nhất là hiệu chỉnh tệp điểm nóng, profile theo giờ, độ nhạy loại đường và mô hình nhiễu bằng dữ liệu GPS, dữ liệu xe công nghệ, camera hoặc dịch vụ giao thông thời gian thực.
- **Mạng đường.** Chưa mô hình hoá đèn tín hiệu, hạn chế rẽ trái/quay đầu và xe máy; phạm vi chỉ là quận cũ cộng 500 m. Khi mở rộng ra toàn thành phố, cần các kỹ thuật tiền xử lý như Contraction Hierarchies phiên bản phụ thuộc thời gian.
- **Dự báo.** GCN hiện chỉ dùng quan sát tức thời; các mô hình không gian–thời gian như DCRNN [7] hay STGCN [8] với lịch sử nhiều bước có thể dự báo tốt hơn.

- **Học tăng cường.** Tinh chỉnh sau học bắt chước nên dùng DAgger đầy đủ hoặc ràng buộc khoảng cách KL với chính sách bắt chước để tránh suy giảm; GNN trên đồ thị lân cận thực (thay cho cây) và ngân sách huấn luyện dài hơn; ứng dụng RL ở cấp quyết định cao hơn (chọn hành lang, chọn giờ với đặc trưng phong phú hơn).
- **Nhiều xe.** Hàm BPR là mô hình đơn giản; cần mô phỏng vi mô hoặc gán luồng động và tính cân bằng người dùng.
- **Rủi ro.** Dùng ngân hàng kịch bản lớn hơn, mô hình sự cố có xác suất theo từng đoạn đường, hoặc mục tiêu trung bình–phương sai thay cho phân vị.

Tài liệu tham khảo

[1] E. W. Dijkstra, "A note on two problems in connexion with graphs," *Numerische Mathematik*, vol. 1, pp. 269–271, 1959.

[2] P. E. Hart, N. J. Nilsson, and B. Raphael, "A formal basis for the heuristic determination of minimum cost paths," *IEEE Transactions on Systems Science and Cybernetics*, vol. 4, no. 2, pp. 100–107, 1968.

[3] K. L. Cooke and E. Halsey, "The shortest route through a network with time-dependent internodal transit times," *Journal of Mathematical Analysis and Applications*, vol. 14, no. 3, pp. 493–498, 1966.

[4] S. E. Dreyfus, "An appraisal of some shortest-path algorithms," *Operations Research*, vol. 17, no. 3, pp. 395–412, 1969.

[5] D. Delling and D. Wagner, "Time-dependent route planning," in *Robust and Online Large-Scale Optimization*, vol. 5868 of *Lecture Notes in Computer Science*, pp. 207–230, Springer, 2009.

[6] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*. MIT Press, 2 ed., 2018.

[7] Y. Li, R. Yu, C. Shahabi, and Y. Liu, "Diffusion convolutional recurrent neural network: Data-driven traffic forecasting," in *International Conference on Learning Representations (ICLR)*, 2018.

[8] B. Yu, H. Yin, and Z. Zhu, "Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting," in *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 3634–3640, 2018.

[9] G. Boeing, "OSMnx: New methods for acquiring, constructing, analyzing, and visualizing complex street networks," *Computers, Environment and Urban Systems*, vol. 65, pp. 126–139, 2017.

[10] U.S. Bureau of Public Roads, *Traffic Assignment Manual*. Washington, D.C.: U.S. Department of Commerce, Urban Planning Division, 1964.

[11] D. E. Kaufman and R. L. Smith, "Fastest paths in time-dependent networks for intelligent vehicle-highway systems application," *IVHS Journal*, vol. 1, no. 1, pp. 1–11, 1993.

[12] A. Orda and R. Rom, "Shortest-path and minimum-delay algorithms in networks with time-dependent edge-length," *Journal of the ACM*, vol. 37, no. 3, pp. 607–625, 1990.

[13] J. Y. Yen, "Finding the k shortest loopless paths in a network," *Management Science*, vol. 17, no. 11, pp. 712–716, 1971.

[14] J. G. Wardrop, "Some theoretical aspects of road traffic research," *Proceedings of the Institution of Civil Engineers*, vol. 1, no. 3, pp. 325–378, 1952.

[15] A. V. Goldberg and C. Harrelson, "Computing the shortest path: A* search meets graph theory," in *Proceedings of the Sixteenth Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, pp. 156–165, 2005.

[16] R. Geisberger, P. Sanders, D. Schultes, and D. Delling, "Contraction hierarchies: Faster and simpler hierarchical routing in road networks," in *Experimental Algorithms (WEA 2008)*, vol. 5038 of *Lecture Notes in Computer Science*, pp. 319–333, Springer, 2008.

[17] H. Bast, D. Delling, A. Goldberg, M. Müller-Hannemann, T. Pajor, P. Sanders, D. Wagner, and R. F. Werneck, "Route planning in transportation networks," in *Algorithm Engineering: Selected Results and Surveys*, vol. 9220 of *Lecture Notes in Computer Science*, pp. 19–80, Springer, 2016.

[18] S. Ichoua, M. Gendreau, and J.-Y. Potvin, "Vehicle dispatching with time-dependent travel times," *European Journal of Operational Research*, vol. 144, no. 2, pp. 379–396, 2003.

[19] A. Stentz, "Optimal and efficient path planning for partially-known environments," in *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, pp. 3310–3317, 1994.

[20] S. Koenig and M. Likhachev, "D* lite," in *Proceedings of the Eighteenth National Conference on Artificial Intelligence (AAAI)*, pp. 476–483, 2002.

[21] J. A. Boyan and M. L. Littman, "Packet routing in dynamically changing networks: A reinforcement learning approach," in *Advances in Neural Information Processing Systems 6*, pp. 671–678, 1994.

[22] C. J. C. H. Watkins and P. Dayan, "Q-learning," *Machine Learning*, vol. 8, pp. 279–292, 1992.

[23] V. Mnih, K. Kavukcuoglu, D. Silver, *et al.*, "Human-level control through deep reinforcement learning," *Nature*, vol. 518, pp. 529–533, 2015.

[24] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," 2017.

[25] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, "Stable-baselines3: Reliable reinforcement learning implementations," *Journal of Machine Learning Research*, vol. 22, no. 268, pp. 1–8, 2021.

[26] S. Huang and S. Ontañón, "A closer look at invalid action masking in policy gradient algorithms," in *Proceedings of the International FLAIRS Conference*, vol. 35, 2022.

[27] A. Y. Ng, D. Harada, and S. Russell, "Policy invariance under reward transformations: Theory and application to reward shaping," in *Proceedings of the Sixteenth International Conference on Machine Learning* (*ICML*), pp. 278–287, 1999.

[28] Y. Bengio, J. Louradour, R. Collobert, and J. Weston, "Curriculum learning," in *Proceedings of the 26th International Conference on Machine Learning* (*ICML*), pp. 41–48, 2009.

[29] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[30] S. Ross, G. J. Gordon, and J. A. Bagnell, "A reduction of imitation learning and structured prediction to no-regret online learning," in *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics* (*AISTATS*), pp. 627–635, 2011.

[31] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *International Conference on Learning Representations (ICLR)*, 2017.

[32] S. K. Lam, A. Pitrou, and S. Seibert, "Numba: A LLVM-based Python JIT compiler," in *Proceedings of the Second Workshop on the LLVM Compiler Infrastructure in HPC*, pp. 7:1–7:6, 2015.

[33] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

[34] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

A Phụ lục: Tham số cấu hình

Bảng A.1 liệt kê các tham số chính trong tệp `configs/config.yaml`. Mọi tham số của dự án đều nằm trong tệp này; chế độ *smoke* ghi đè một số tham số để chạy nhanh.

B Phụ lục: Các điểm nóng ùn tắc

Các hệ số trong Bảng B.1 là **giả định** của nhóm dựa trên hiểu biết chung về giao thông khu vực Hà Đông, không phải số đo, và cần được hiệu chỉnh theo trải nghiệm thực tế hoặc dữ liệu đo. Toạ độ các điểm nóng xác định theo bán kính được lấy từ dịch vụ Nominatim (OpenStreetMap).

Bảng A.1: Tham số cấu hình chính (configs/config.yaml).

Khoá	Giá trị	Ý nghĩa
`graph.buffer_m`	500	vùng đệm quanh ranh giới quận (m)
`graph.free_flow_factor`	0.9	v_free = maxspeed × hệ số
`speed.c_max / v_min`	0.85 / 5.0	chặn trên ùn / vận tốc tối thiểu (km/h)
`speed.profile.peaks`	morning: μ=8.0, σ=1.0, a=0.58; midday: μ=12.5, σ=2.5, a=0.25; evening: μ=18.0, σ=1.2, a=0.62; late_evening: μ=21.0, σ=1.5, a=0.12	Gaussian tuần hoàn
`speed.road_sensitivity`	trunk:1.0, primary:0.95, secondary:0.8, tertiary:0.65, residential:0.4	s(nhóm đường)
`speed.direction.beta`	0.3	biên độ hệ số hướng
`speed.real_noise`	correlated, ρ=0.8, k=4, iid=0.3	nhiễu môi trường thực
`speed.fifo.max_slope`	0.9	giới hạn $-d\tau/dt$
`speed.incidents`	hệ số [0.1, 0.4], [30, 120] phút	sự cố
`scenarios.n_queries`	1000	số truy vấn (full)
`scenarios.sigma_levels`	[0.05, 0.15, 0.3]	mức nhiễu
`scenarios.*on_route_prob`	chính 0.0, stress 0.7	xác suất đặt sự cố trên tuyến
`algorithms.replan`	r=400 m, lười θ=0.15	quan sát / replan lười
`algorithms.dstar.refresh_min`	15	chu kỳ dựng lại D* Lite (phút)
`algorithms.alt.n_landmarks`	8	số điểm mốc ALT
`algorithms.risk`	M=30, k=6, q=0.9	định tuyến P90
`forecast`	cảm biến 0.15, GCN 3×32, 1500 bước	dự báo ngắn hạn
`rl.ppo`	lr=0.0003, n_steps=512×8, batch=256, γ=0.995, ent=0.01	MaskablePPO
`rl.variants`	rl=400000; rl_ctg=400000; rl_shape=1000000; rl_tree=800000; rl_lstm=500000; rl_tree_bc=800000; rl_hybrid=60000	bước huấn luyện / seed
`rl.bc`	1500 tập, 8 epoch, khám phá 0.2	behavior cloning
`env.reward`	time_weight=1.0, shaping=euclid, shaping_lambda=1.0, shaping_ref_speed_kmh=30, goal_bonus=10.0, revisit_penalty=1.0, timeout_penalty=10.0, deadend_penalty=10.0	hệ số thưởng
`departure`	bước 10 phút ×6, w=[1.0, 0.5, 0.25]	chọn giờ xuất phát
`multiagent`	20 xe/tác tử, BPR α=0.5, β=2.0	mô phỏng nhiều xe

Bảng B.1: Các điểm nóng (giả định cần hiệu chỉnh) và số cạnh được khớp.

Điểm/trục nóng	Hệ số	Khung giờ [bắt đầu, kết thúc)	Số cạnh khớp	Chiều dài (km)
Quang Trung	1,30	[[6, 10], [16, 20]]	88	14,3
Nguyen Trai	1,35	[[6, 10], [16, 20]]	20	1,8
To Huu (Le Van Luong keo dai)	1,30	[[6, 10], [16, 20]]	29	4,7
Van Khe	1,20	[[7, 9], [16, 19]]	33	5,5
Quoc lo 6	1,25	[[6, 10], [16, 20]]	141	23,9
Cau Am	1,35	[[6, 10], [16, 20]]	46	4,6
Mai Linh	1,25	[[6, 9], [16, 19]]	6	2,5
Ben xe Yen Nghia	1,30	[[5, 9], [15, 20]]	138	9,3
Tran Phu	1,25	[[6, 10], [16, 20]]	31	3,8
Phung Hung	1,20	[[7, 9], [16, 19]]	39	4,3